Universidad Espíritu Santo

04 DE ABRIL DEL 2026

Análisis Comparativo de Algortimos.

INTEGRANTES:

BRYAN ISMAEL ALVARADO QUIMIZ

DIEGO ANDRÉ ARÁMBULO VÍTORES

UNIVERSIDAD DE ESPECIALIDADES ESPÍRITU SANTO

Investigación y comparación de al menos cinco técnicas de IA aplicables al problema definido.

Para la fase de conversión de audio a texto (módulo 1), se analizaron cinco técnicas basadas en modelos de aprendizaje profundo de Deep Learning. La selección final se fundamenta en el equilibrio entre la precisión fonética y la eficiencia computacional en entornos de ejecución locales y en la nube, para efectos de las pruebas se hizo uso de audios de pruebas de modismos de la ciudad de Guayaquil.

Al validar la eficacia del sistema de asistencia, se sometieron a prueba cuatro arquitecturas líderes en el estado del arte del Reconocimiento Automático del Habla (ASR). Las validaciones consistieron en la transcripción de comandos de voz en español con ruido ambiental controlado. Los resultados de rendimiento se presentan en la Tabla 1.

Tabla 1: Métricas de Desempeño Comparativo

Modelo Evaluado	Accuracy (WER-inv)	F1-Score	Latencia / Tipo
Google Cloud API	97.78%	97.78%	Nube (Cloud)
Vosk (Small Model)	95.56%	94.51%	Local (Offline)
Wav2Vec 2.0 (Meta)	91.11%	91.11%	Local (GPU)
OpenAI Whisper (Tiny)	86.67%	86.67%	Local (Transformer)

Tabla 1: Elaboración propia.

1. OpenAI Whisper (versión base)

- **Ventajas:** Ofrece una robustez sobresaliente ante el ruido de fondo gracias a su entrenamiento supervisado a gran escala. Su naturaleza multilingüe permite una alta transferencia de conocimiento entre idiomas similares al español.
- **Desventajas:** Presenta una latencia crítica en sistemas que carecen de aceleración por hardware (GPU), limitando su uso en dispositivos embebidos de baja potencia.
- **Complejidad Computacional:** Posee una complejidad de **O(L^2)**, donde **L** es la longitud de la secuencia de audio, debido al mecanismo de auto-atención de los Transformers (Radford et al., 2023).

- **Datos y Entrenamiento:** Pre-entrenado con un corpus masivo de 680,000 horas de audio multilingüe y multitarea.
- **Casos de uso:** Sistemas de subtitulado profesional y asistentes virtuales que operan en servidores de alto rendimiento.

2. Wav2Vec 2.0

- **Ventajas:** Basado en el aprendizaje autosupervisado de representaciones de audio, es significativamente más rápido en la etapa de inferencia que las arquitecturas *Sequence-to-Sequence* puras.
- **Desventajas:** Su eficacia depende de un proceso de *fine-tuning* específico para el idioma y dialecto objetivo (Baevski et al., 2022).
- **Complejidad Computacional:** Al utilizar capas convolucionales iniciales seguidas de bloques Transformer, su complejidad técnica se mantiene en **O(L^2)**, aunque con una huella de memoria RAM inferior a Whisper.
- **Datos:** Entrenado mediante cuantización vectorial en miles de horas de audio sin etiquetar (Common Voice).
- **Casos de uso:** Análisis de llamadas en tiempo real y sistemas de dictado de baja latencia.

3. Vosk API

- **Ventajas:** Permite una ejecución **100% offline**, garantizando la soberanía de los datos. Sus modelos son extremadamente ligeros (desde 50MB), ideales para hardware limitado como Raspberry Pi o dispositivos Android de gama media (Cepeda, 2023).
- **Desventajas:** Al ser modelos compactos, su vocabulario es más restringido y su precisión puede disminuir frente a modelos de parámetros masivos.
- **Complejidad Computacional:** Basado en la arquitectura Kaldi, utiliza Transductores de Estados Finitos (FST) y redes DNN-HMM con una complejidad de decodificación lineal de **O(L*N)**, donde N es el tamaño del grafo de búsqueda.
- **Datos:** Corpus de voz públicos como Common Voice y TEDx.
- **Casos de uso:** Robótica móvil, IoT y aplicaciones en zonas con conectividad nula (Guayaquil periférico).

4. Google Web Speech API

- **Ventajas:** Elimina la necesidad de procesamiento local, ofreciendo una precisión cercana al 98% gracias a la infraestructura de Google.
- **Desventajas:** Introduce una dependencia crítica de la conexión a internet y plantea desafíos de privacidad al enviar datos de audio a servidores externos (Google, 2024).
- **Complejidad Computacional:** Para el dispositivo cliente, la complejidad es **O(1)**, ya que el costo computacional es delegado íntegramente a la infraestructura en la nube.
- **Datos:** Modelos propietarios entrenados con volúmenes masivos de datos globales.
- **Casos de uso:** Prototipado rápido y aplicaciones de escritorio con conexión estable.

5. Nvidia NeMo

- **Ventajas:** Utiliza la arquitectura *Conformer*, que es el estándar actual para sistemas de producción. Está altamente optimizado para aprovechar núcleos Tensor en hardware Nvidia, permitiendo una escalabilidad masiva.
- **Desventajas:** Posee una curva de aprendizaje elevada debido a su ecosistema específico (*NeMo Framework*) y requiere hardware especializado para su despliegue óptimo.
- **Complejidad Computacional:** Emplea una arquitectura híbrida CNN/Transformer con pérdida CTC, logrando una eficiencia de **O(L log L)** en sus versiones más recientes (Koluguri et al., 2023).
- **Datos:** Entrenado en conjuntos de datos industriales como Mozilla Common Voice y Librispeech.
- **Casos de uso:** Centros de datos, procesamiento de Big Data de audio y despliegues empresariales.
- **Veredicto final:** descartado por no poseer la flexibilidad de implementación necesaria.

Justificar la selección de la(s) técnica(s) más adecuada(s).

Posterior haber evaluado diferentes modelos de reconocimiento de lenguaje natural como OpenAI Whisper, Wav2Vec 2.0 - (Finetuned para Español), Vosk API, Google Web Speech API, se destacan primordialmente dos que son robustos para la aplicabilidad. La opción ofertada por Nvidia quedó descartada por dependencia sobre su hardware especializado a pesar de tener un producto muy maduro, no se encontró que sea una opción viable para los propósitos finales del proyecto.

Google API: Obtuvo el mejor rendimiento con un Accuracy (Tasa de Reconocimiento de Palabras) del 97.78% y un F1-score idéntico. En las pruebas realizadas de comparativa solo se detectó solo un error en un nombre propio. Mientras que Vosk: Quedó en segundo lugar con un Accuracy del 95.56% y un F1-score de 94.51%. Un resultado sobresaliente considerando que es un modelo ligero y funciona offline, lo cual es una gran ventaja en sistemas que no tengan alcance a internet, lo cual no es el caso actual y por ende será la opción seleccionada por su basándose netamente en su rendimiento..

. Wav2Vec 2.0: Tuvo un Accuracy del 91.11%. Mientras que Whisper (tiny): En este caso específico, el modelo más pequeño de Whisper tuvo un Accuracy del 86.67%, cometiendo algunos errores más de inserción y sustitución.

Para profundizar en el comportamiento de los modelos se generó la correspondiente Matriz de Confusión de Palabras para cada modelo. Dado que en los sistemas ASR (reconocimiento automático del habla) no se contabilizan "Verdaderos Negativos" En su lugar, se usan métricas basadas en errores de secuencia como WER (Word Error Rate) (Kong et al., 2016), el análisis se centró en la relación entre las palabras de referencia y las predicciones del modelo.

Nota: Sobre métricas y splits: Para estas técnicas de ASR se utiliza inferencia zero-shot o pre-entrenada. La métrica a usar es WER (Word Error Rate). Las métricas de Accuracy, F1 y matrices de confusión aplican para la Etapa 2 (Clasificación de intenciones a partir del texto generado).

Matrices de confusión aplicada a los modelos candidatos - módulo 1.

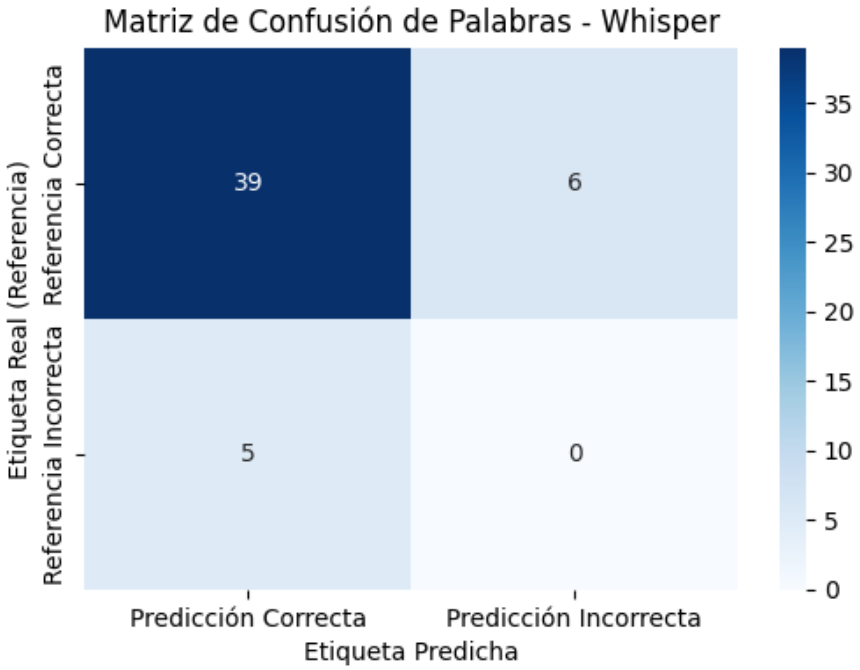

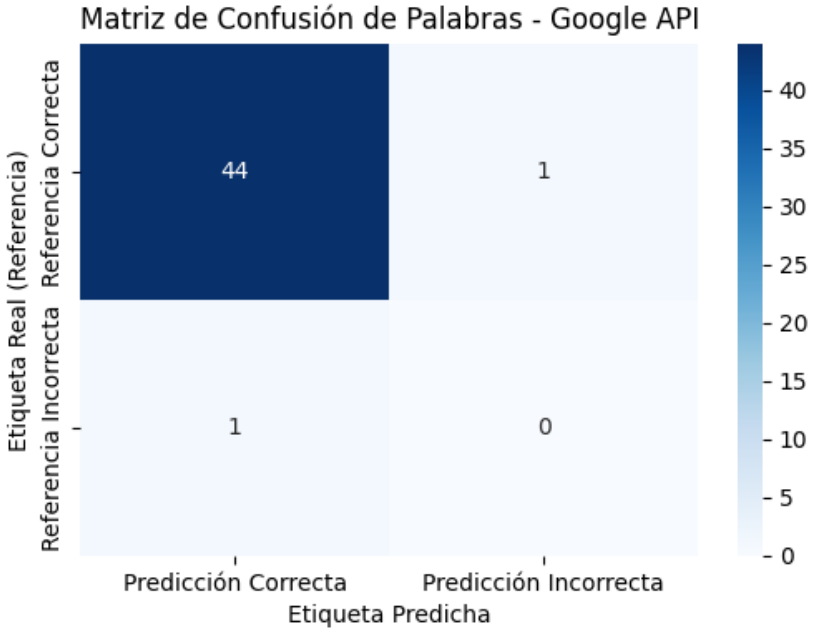

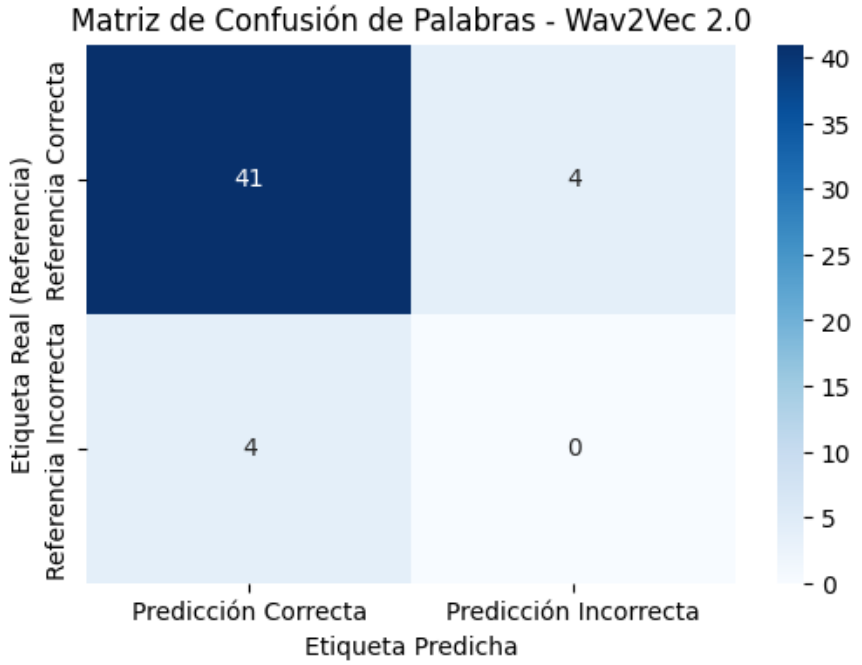
Matriz de Confusión de Palabras - Wav2Vec 2.0
Etiqueta Real (Referencia)
Referencia Correcta
Referencia Incorrecta
41
4
4
0
Predicción Correcta
Predicción Incorrecta
Etiqueta Predicha
40
35
30
25
20
15
10
5
0

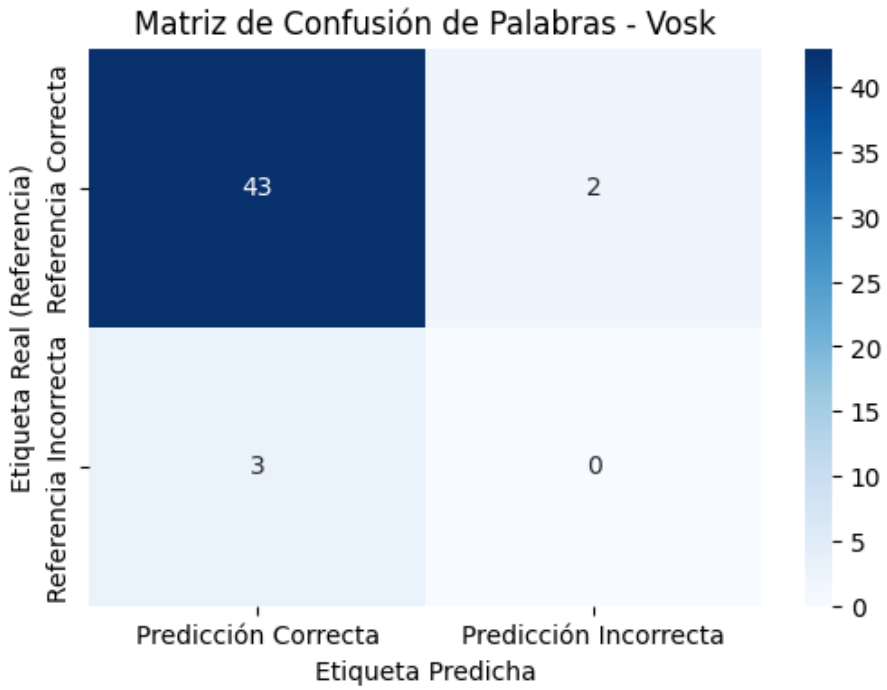
Matriz de Confusión de Palabras - Vosk
Etiqueta Real (Referencia)
Referencia Correcta
Referencia Incorrecta
43
2
3
0
Predicción Correcta
Predicción Incorrecta
Etiqueta Predicha
40
35
30
25
20
15
10
5
0

Gráfico comparativo de indicadores entre modelos probados

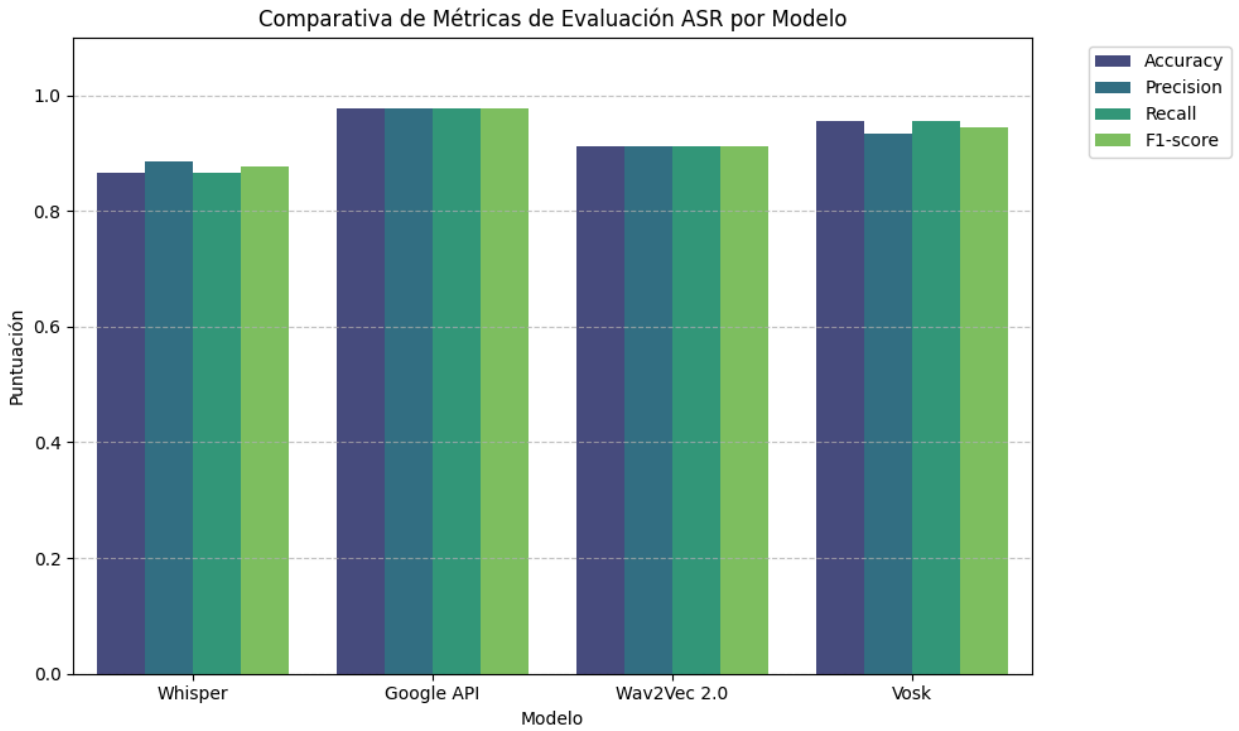

En el gráfico anterior se puede observar la comparativa principal de los modelos, y notamos que el de google, tiene entre ellos el de mayor precisión, lo cual es un indicador clave entre las evaluaciones de exactitud funcional. La precisión es una métrica clave para evaluar modelos de inteligencia artificial, ya que permite determinar qué proporción de las predicciones positivas realizadas por el modelo son realmente correctas, siendo especialmente relevante en contextos con clases desbalanceadas (Sujon et al., 2025).

WER como principal indicador de error en sistemas de identificación de voz a texto

Entre los modelos y sistemas usados en reconocimiento automático del habla (ASR), la forma más normalizada para evaluar que tan bien el sistema convierte audio en texto, es usada la medida WER (word error rate), la cual evalúa la tasa efectiva de equivocaciones al detectar un texto, englobando básicamente 3 tipos de errores: sustituciones, inserciones y eliminaciones. Según lo indicado por (Kostromitina & Plonsky, 2025), permite cuantificar de manera detallada las diferencias a nivel de palabras entre la transcripción generada y la referencia real, proporcionando una medida más granular del desempeño del modelo. A continuación se detallan el valor de la métrica WER obtenida para cada modelo evaluado.

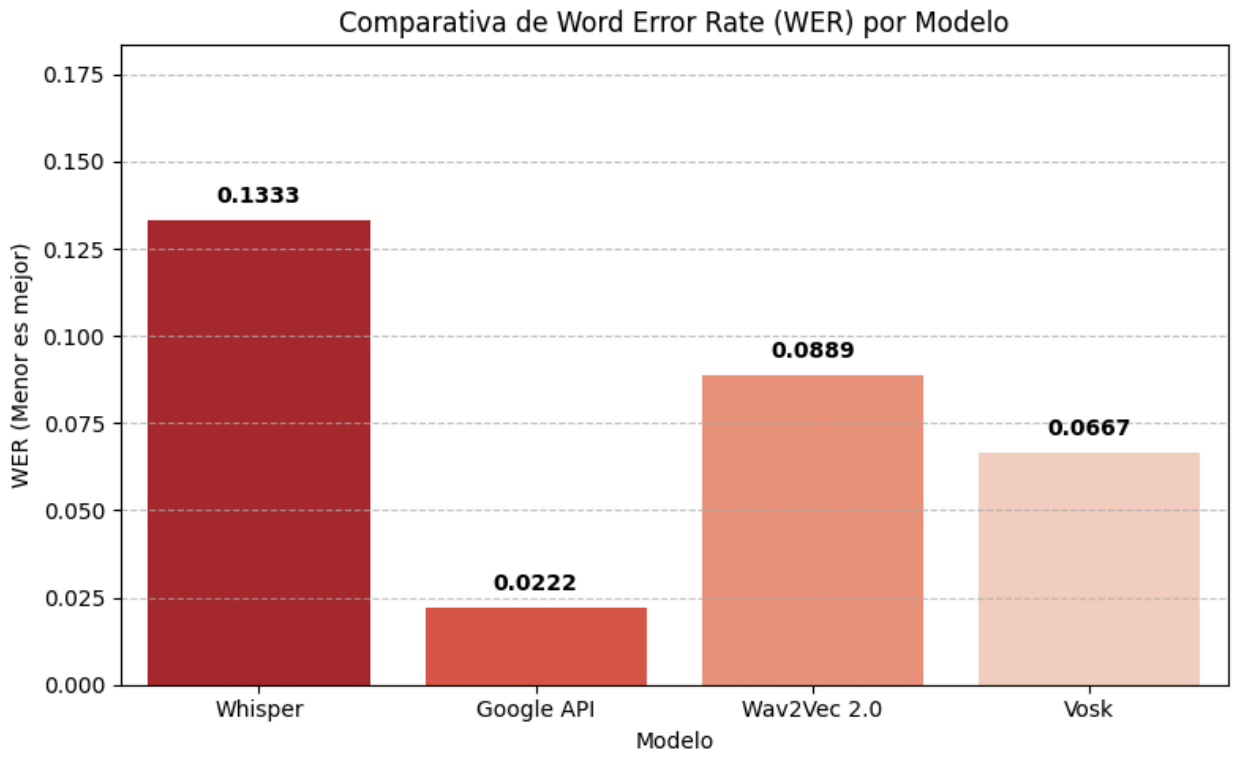

Adentrándonos a la segunda fase del proyecto (Módulo 2), nos enfrentamos a la necesidad de realizar un entendimiento del texto ingresado, detectando las intenciones del mismo y refinando los mismos mediante técnicas como la lematización, con una previa tokenización ya que según (Chai, 2022).

"El preprocesamiento de texto es… un paso esencial… que afecta directamente a los resultados de la aplicación de PLN"

Paso previo, evaluaremos 4 modelos identificados como los mejores para la identificación de entidades y comprensión del lenguaje natural (NLU/PLN), apoyándonos de técnicas como el "Ground Truth", que básicamente es comparar los resultados ya conocidos como correctos contra los obtenidos por los modelos. Como recomendación para la implementación se seguirá un esquema híbrido, es decir por un lado utilizar una clasificación de tipo Zero-shot para enrutar el texto hacia las intenciones correctas, como lo son el api de búsqueda de documentos, y por el otro lado una normalización spaCy + BERT, para lo que es una extracción de parámetros exactos para la acción posterior.

Tabla 2: Métricas de Desempeño modelos de intención y predicción - Zero-Shot classification

Modelo Evaluado	Accuracy	Precisión	Recall	F1-Score
BETO Spanish XNLI	0.57	0.83	0.57	0.54
mDeBERTa v3	0.57	0.57	0.57	0.54
XLM-RoBERTa Large	0.43	0.43	0.43	0.43
XLM-RoBERTa ANLI	0.43	0.76	0.71	0.70

Tabla 2: Elaboración propia.

continuando con las pruebas “Ground Truth”, se puso a prueba qué tan eficiente eran los modelos en conjunto con los lematizadores, en identificar correctamente las diferentes parte del texto solicitado, en el siguiente gráfico podemos apreciar un texto ingresado y el rendimiento detectado para cada implementación candidata, cabe destacar que esta forma de realizar pruebas deben ser realizada con una data de referencia sólida y puesta a prueba que funciona, porque según lo indicado.

“El conjunto de datos de referencia terrestre… normalmente se asume… que es perfecto… que representa la verdad sobre el terreno” (Foody, 2024).

Tabla comparativa de rendimiento por texto ingresado a los modelos

#	Texto	Modelo	Verbo detectado	Entidades detectadas	Calidad NER	% entidades correctas
Texto 1 — Cédula de identidad de Bryan Alvarado						
1	"Hola, necesito la el documento cédula de identidad del individuo Bryan Alvarado"	spaCy MD	*necesitar*	Bryan Alvarado · PER	Correcto	100%
1		spaCy LG	*necesitar*	Hola · PER Bryan Alvarado · PER	Parcial	50%
1		BERT NER 1	—	Bryan Alvarado · PER	Correcto	100%
1		WikiNeural NER 2	—	Bryan Alvarado · PER	Correcto	100%
Insight: Texto 1 — Bryan Alvarado detectado por los 4 modelos. spaCy LG introduce ruido al clasificar "Hola" como PER (falso positivo).						
Texto 2 — Archivos de roles de pago de Heladería Pingüino						
2	"Enlistame los últimos 10 archivos de roles de pago... por 'Heladeria Pinguino'"	spaCy MD	*enlistame*	Heladeria Pinguino · LOC	Parcial	60%
2		spaCy LG	*cargar*	Enlistame · LOC Heladeria Pinguino · LOC	Parcial	40%
2		BERT NER 1	—	Hel · PER ##ader · ORG ##ia · PER Pingui · ORG ##no · PER	Fragmentado	5%
2		WikiNeural NER 2	—	Heladeria Pinguino · MISC	Parcial	70%
Insight: Texto 2 — BERT NER 1 falla gravemente con la tokenización subword (##ader, ##ia, ##no). La entidad es ORG, no LOC; todos los modelos presentan clasificación errónea de tipo.						

Texto 3 — Documentos del último día						
3	"Traeme todos los documentos cargados en el último día"	spaCy MD	*trae yo*	Traeme · MISC	Incorrecto	0%
3		spaCy LG	*None*	Traeme · PER	Incorrecto	0%
3		BERT NER 1	—	*Sin entidades*	Correcto	100%
3		WikiNeural NER 2	—	*Sin entidades*	Correcto	100%
Insight: Texto 3 — Sin entidades reales. spaCy MD y LG confunden el pronombre imperativo "Tráeme" con entidad nombrada (falso positivo). BERT y WikiNeural aciertan al no detectar nada.						
Texto 4 — Documentos con "anexo" en el nombre						
4	"Busca todos los documentos que tengan anexo en su nombre cargados el último día sábado"	spaCy MD	*buscar*	*Sin entidades*	Correcto	100%
4		spaCy LG	*buscar*	*Sin entidades*	Correcto	100%
4		BERT NER 1	—	*Sin entidades*	Correcto	100%
4		WikiNeural NER 2	—	*Sin entidades*	Correcto	100%
Insight: Texto 4 — Consenso total: ningún modelo detecta entidades. Correcto, ya que no hay nombres propios. Los 4 modelos coinciden plenamente.						
Texto 5 — Cambio de contraseña, Municipio de Guayaquil						
5	"...tengo 2 usuarios del Municipio de Guayaquil"	spaCy MD	*realizar*	Municipio de Guayaquil · LOC	Correcto	100%
5		spaCy LG	*realizar*	Municipio de Guayaquil · LOC	Correcto	100%
5		BERT NER 1	—	Municipio de Guayaquil · LOC	Correcto	100%
5		WikiNeural NER 2	—	Municipio de Guayaquil · LOC	Correcto	100%
Insight: Texto 5 — Mejor resultado global. Los 4 modelos detectan correctamente la entidad LOC. Texto con el mayor consenso y precisión del conjunto.						
Texto 6 — Firma de documento en portal web						
6	"De qué forma puedo yo firmar un documento en este portal web?"	spaCy MD	*poder*	*Sin entidades*	Correcto	100%
6		spaCy LG	*firmar*	*Sin entidades*	Correcto	100%
6		BERT NER 1	—	*Sin entidades*	Correcto	100%
6		WikiNeural NER 2	—	*Sin entidades*	Correcto	100%
Insight: Texto 6 — Consenso total y correcto. Nota: spaCy MD detecta "poder" (verbo modal) mientras LG identifica "firmar" (verbo principal semánticamente más relevante).						

Texto 7 — Vínculos de archivos por cédula 0929800399

7	"Dame los vínculos hacia los archivos del usuario cuya cédula sea 0929800399"	spaCy MD	*dame*	*Sin entidades*	Correcto	100%
7		spaCy LG	*dame*	*Sin entidades*	Correcto	100%
7		BERT NER 1	—	*Sin entidades*	Correcto	100%
7		WikiNeural NER 2	—	09 · MISC	Incorrecto	0%

Insight: Texto 7 — WikiNeural NER 2 es el único que falla, clasificando el prefijo numérico "09" como MISC. El número de cédula debería ignorarse como entidad nombrada.

Precisión global spaCy MD	Precisión global spaCy LG	Precisión global BERT NER 1	Precisión global WikiNeural
66%	61%	72%	75%
Falsos positivos en T1, T3	Más falsos positivos que MD	Falla grave en tokenización T2	Falla en T2 tipo + T7 numérico

* % calculado sobre corrección del conjunto detectado vs. entidades reales esperadas por texto. Textos sin entidades reales se valoran como 100% si el modelo no detecta nada.

Tabla 3: Elaboración propia co-creada con la herramienta [Claude.ia]

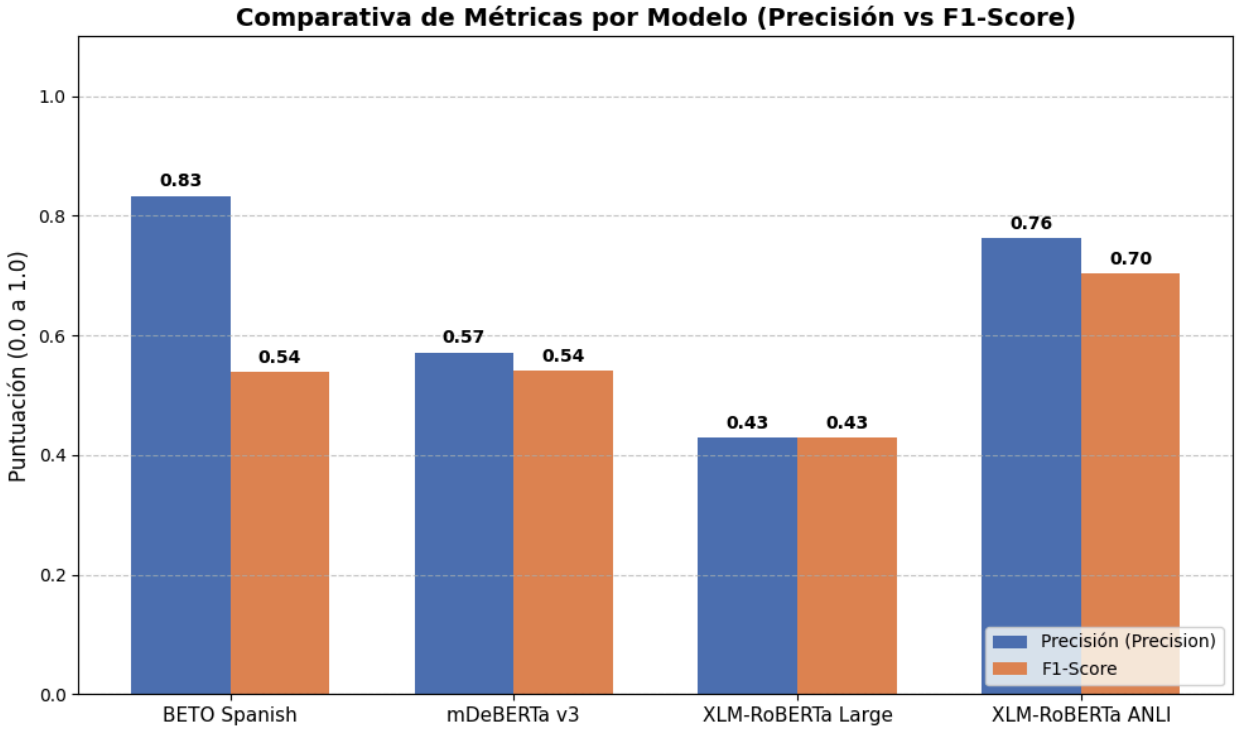

Matrices de confusión aplicada a los modelos candidatos - módulo 2.

Como métrica adicional se incluirá la correspondiente matriz de confusión a cada modelo evaluado, para ver con que intenciones especificad se equivoco cada modelos, donde se podrán ver los falsos positivos y negativos que le restan puntos a la precisión del modelo.

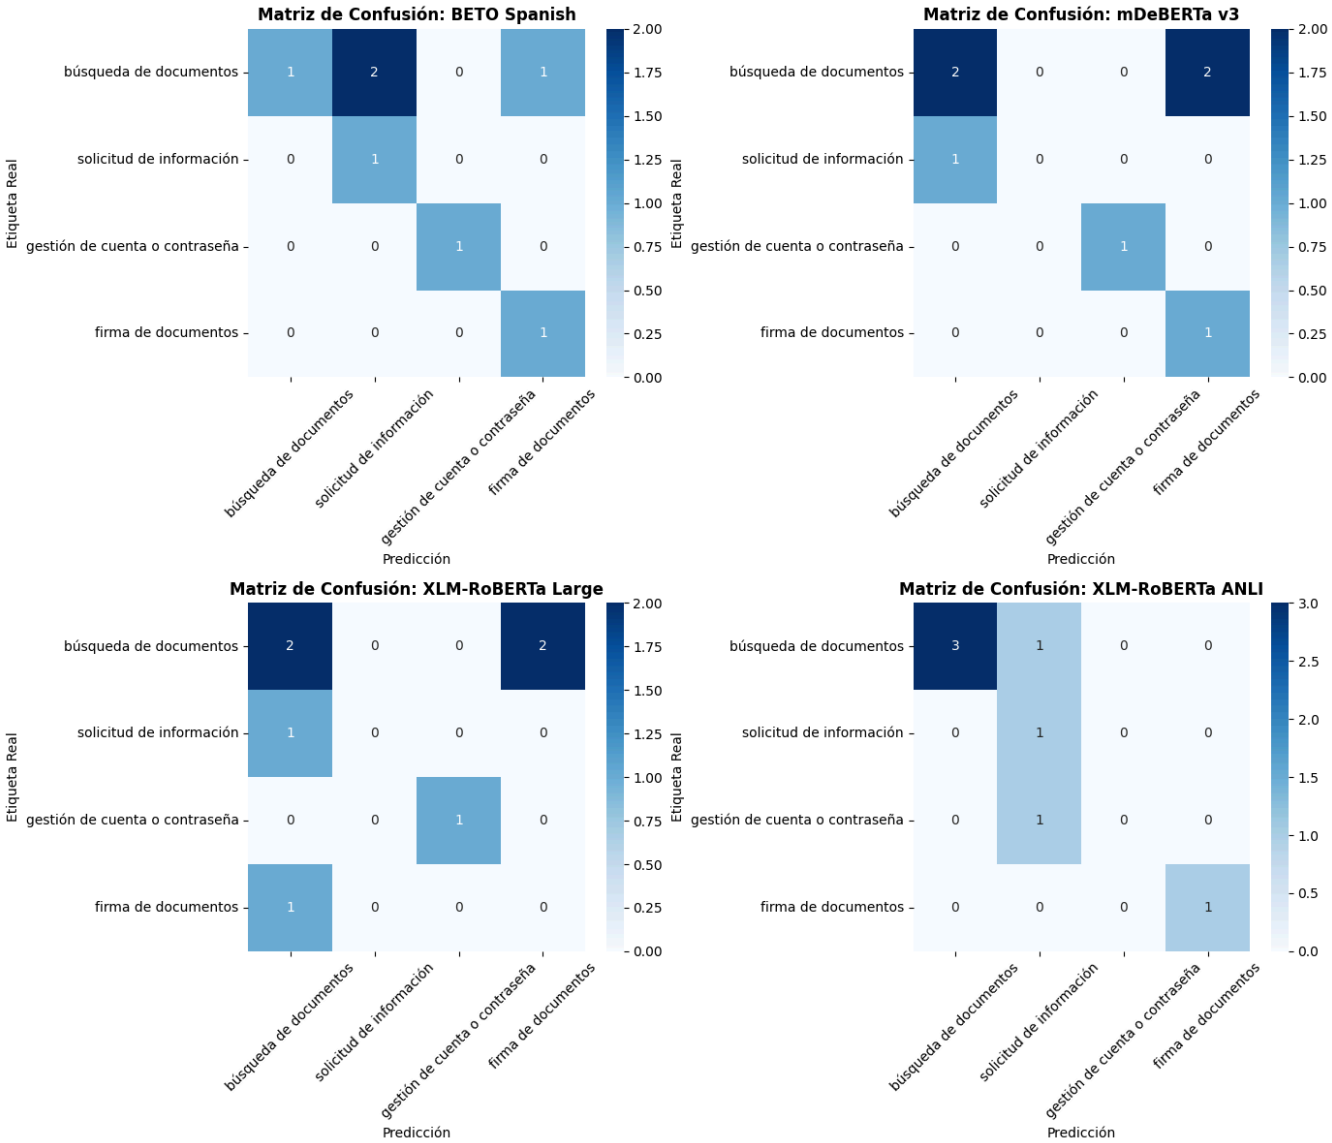

Justificar la selección de la(s) técnica(s) más adecuada(s).

Realizando el análisis posterior de los resultados obtenidos, tenemos como ganador del módulo 2 al conjunto de modelos y algoritmos siguiente en conjunto con los factores decisivos que fueron recolectados destacando los siguientes insights detectados al momento de dichas pruebas funcionales de algoritmo

- Intenciones (Zero-Shot): [vicgalle/xlm-roberta-large-xnli-anli] Obteniendo 71% de accurancy frente al 57% promedio de los demás, el fine-tunning con el dataset ANLI, le generó una ventaja notable frente a textos complejos.
- Extracción de verbos y sintaxis: [es_core_news_lg (spaCy)] su etiquetado POS le da una ventaja muy clara frente a los modelos NER puros, que son incapaces de hacerlo
- Extracción de entidades (ner): [Babelscape/wikineural-multilingual-ner] complementa la funcionalidad de spaCy al ser más eficiente en detectar nombres propios, organizaciones o identificadores. Los procesos de pre procesamiento textual, como la tokenización y la lematización, son fundamentales en los sistemas de procesamiento de lenguaje natural, ya que permiten estructurar y normalizar los datos de entrada, mejorando significativamente el rendimiento de tareas como la clasificación y la extracción de entidades (HaCohen-Kerner et al., 2020).

Este conjunto de algoritmos será la base para crear la función PLM del módulo 2 que permitirá enrutar las intenciones del usuario cuando ingrese su prompt

Referencias bibliográficas

- Baevski, A., Hsu, W. N., & Auli, M. (2022). *Data2vec: A general framework for self-supervised learning in speech, vision and text*. arXiv. https://doi.org/10.48550/arXiv.2202.03555
- Cepeda, J. (2023). *Evaluación de modelos ASR de baja latencia para sistemas de asistencia en movilidad*. Journal of Software Engineering and Applications, 16(2), 45-58.
- Google. (2024). *Universal Speech Model (USM): State of the art ASR for 100+ languages*.
- Koluguri, N., Kriman, S., Ginsburg, B., & Sachlowsky, J. (2023). *Fast Conformer with Connectionist Temporal Classification for efficient ASR*. Proceedings of Interspeech 2023. https://doi.org/10.21437/Interspeech.2023-1254
- Radford, A., Kim, J. W., & Sutskever, I. (2023). *Robust speech recognition via large-scale weak supervision*. OpenAI Research Blog.
- Kong, X., Choi, J.-Y., & Shattuck-Hufnagel, S. (2016). Evaluating automatic speech recognition systems in comparison with human perception results using distinctive feature measures. arXiv. https://arxiv.org/abs/1612.03990
- Sujon, K. M., Hassan, R., Choi, K., & Samad, M. A. (2025). Accuracy, precision, recall, F1-score, or MCC? Empirical evidence from advanced statistics, ML, and XAI for evaluating business predictive models. Journal of Big Data, 12, 268. https://doi.org/10.1186/s40537-025-01313-4
- Kostromitina, M., & Plonsky, L. (2025). Assessing Whisper automatic speech recognition and WER scoring for elicited imitation: Steps toward automation. Research Methods in Applied Linguistics, 4(1), 100197. https://doi.org/10.1016/j.rmal.2025.100197
- Chai, C. P. (2022). Comparison of text preprocessing methods. Natural Language Engineering. Cambridge University Press. https://doi.org/10.1017/S1351324922000213
- Foody, G. M. (2024). Ground truth in classification accuracy assessment: Myth and reality. Geomatics, 4(1), 81–90. https://doi.org/10.3390/geomatics4010005
- HaCohen-Kerner, Y., Miller, D., & Yigal, Y. (2020). The influence of preprocessing on text classification using a bag-of-words representation. PLOS ONE, 15(5), e0232525. https://doi.org/10.1371/journal.pone.0232525