Universidad Espíritu Santo

04 DE ABRIL DEL 2026

Análisis Exploratorio de Datos EDA.

INTEGRANTES:

BRYAN ISMAEL ALVARADO QUIMIZ

DIEGO ANDRÉ ARÁMBULO VÍTORES

UNIVERSIDAD DE ESPECIALIDADES ESPÍRITU SANTO

Desarrollo completo de un análisis exploratorio de datos utilizando herramientas que permitan el desarrollo completo.

El análisis exploratorio de datos permitió identificar las características principales del corpus textual, así como evaluar la calidad de las transcripciones generadas por el sistema ASR y su impacto en la detección de intenciones. Asimismo, se analizaron las distribuciones de clases y la variabilidad lingüística del conjunto de entrenamiento.

El presente trabajo, está separado en 3 módulos que en conjunto formarán un solo pipeline de trabajo (ASR + NLU + API), debido a que es una propuesta multidisciplinaria que comprende la comunicación asertiva de diferentes elementos, desde el prompt del usuario hasta la invocación al API ya existente.

Análisis de distribuciones de variables.

La propuesta al estar dividida en 3 partes fundamentales estará integrada por fuentes de datos externas, ya existentes y por un set de inputs cargados en el momento de realizar pruebas, siendo estos orígenes ordenados de la siguiente forma:

- **Módulo 1.-** Voz a texto (ASR)
    - set de audios grabados por el usuario emulando flujos y peticiones
    - transcripciones exactas de texto de los audios
    - data errada para control de escenarios
- **Módulo 2.-** Datos de intención (NLU)
    - frases de usuario
    - etiquetas de intencion (acciones que se desean realizar)
    - clasificación por texto etiquetado
- **Módulo 3.-** Manuales existentes (texto técnico y de navegación)
    - Documentación del sistema para usuarios
    - Manuales de API rest con corpus de conocimientos
    - contenido mixto, estructurado y semi estructurado

Identificación de calidad de los datos.

Una de las etapas fundamentales en un análisis de datos y su uso posterior, es la correcta limpieza de los mismos, según indica (To‘xtasinov & Sodiqov, 2025). La limpieza de datos constituye una etapa esencial dentro del análisis de datos, ya que permite mejorar la calidad de la información mediante la corrección de errores, eliminación de inconsistencias y tratamiento de valores faltantes.

La limpieza de datos, incluyendo la eliminación de valores atípicos, datos faltantes y registros mal etiquetados, puede mejorar significativamente el rendimiento de los modelos de aprendizaje automático, llegando a incrementos superiores al 20% en la precisión únicamente mediante procesos de depuración del dataset (Schelter et al., 2022). Es por eso que gran parte de los errores son evitados en esta etapa crítica, cuya importancia radica seccionada en 3 principales secciones y sus análisis claves.

- Módulo 1.- voz a texto (ASR)
    - WER (word error rate)
    - Longitud de audios
    - Duración vs error
    - Distribución de error:
        - sustituciones
        - inserciones
        - eliminaciones
    - Tipo de errores
        - técnicos (ej: al usar conjunto de lenguaje spanglish)
        - comunes
        - controlados
    - Insights esperados
        - tipo de palabra con más tasa de fallo
        - impacto de un fallo en el siguiente módulo (NLU)

- Módulo 2.- Datos de intención (NLU)
    - distribución de clases (existe balance?)
    - número de ejemplos por intent probado
    - frases promedio por clase
    - identificacion de anomalias en intents
        - ambigüedad
        - solapamiento semántico (transmisión de la misma idea)
    - longitud de frases
    - Insights esperados
        - ¿Es necesario más datos?
        - calidad de etiquetado
- Módulo 3.- Manuales existentes (texto técnico y de navegación)
    - Longitud de la documentación
        - conteo de palabras
        - oraciones por documento
    - Frecuencia de términos
        - palabras comunes
        - terminos clave (ej: token, request, endpoint)
    - Distribución del vocabulario
        - palabras únicas (raras contra frecuentes)
    - Ruido en la data
        - símbolos no necesarios e ilegibles
        - códigos, urls, fragmentos de json
    - Información no digerible
        - tablas de difícil lectura
        - anexos de imagen no legible por el modelo que esconda data primordial
        - estilos de archivo que ocupe espacio en memoria al procesar

- Módulos unificado.- Audio + ASR + NLU + API REST
    - Impacto de un error en etapa ASR en NLU
        - afección detectada en la intención por error de ASR
    - Precisión de funcionamiento con texto limpio vs texto identificado por voz
    - Casos fallidos
        - análisis cualitativo de los errores detectados
    - Cobertura de escenarios
        - conteo de intenciones que impactan a un API
        - conteo de intenciones que culminan en una navegación

Pre procesamiento de los datos

Una forma de evaluar correctamente el impacto de las validaciones y pre procesamientos es un análisis directo comparativo, es decir un antes y después de realizar los filtro necesarios, a continuación tomaremos como ejemplo la normalización de los textos que serán identificados, como los son las intenciones capturadas por el modelo

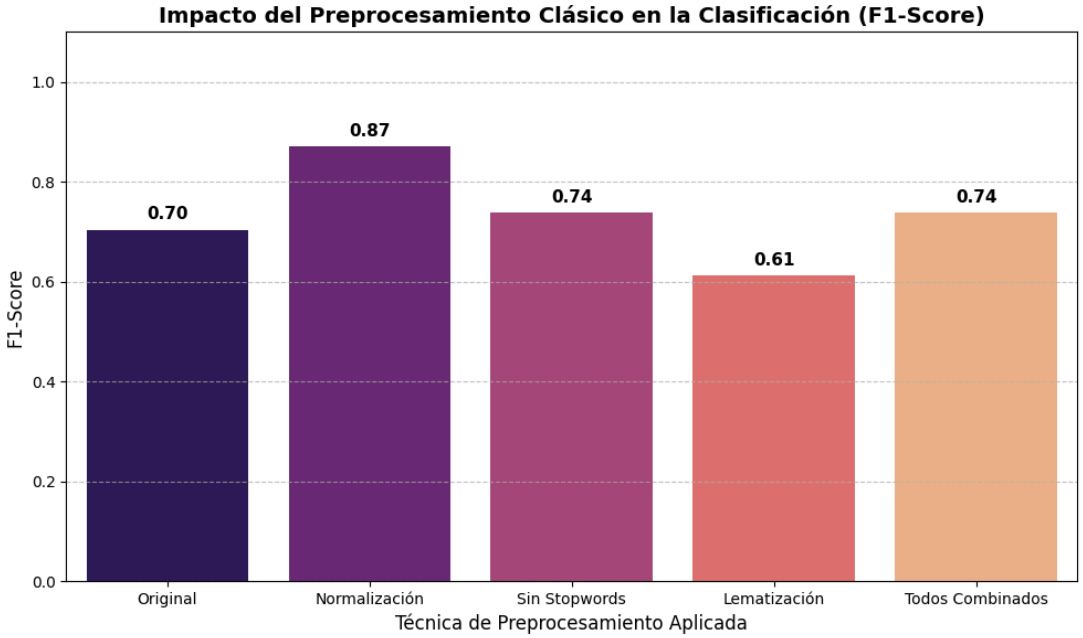

Gráfico 1: Elaboración propia

En la anterior comparación, podemos evidenciar ciertos aspectos como que el pre procesamiento si influye significativamente en el desempeño del modelo, pero no todas las técnicas aportan mejoras, algunas incluso dando perjuicios al modelo, podemos realizar las siguientes interpretaciones.

- **Texto original (0.70)**
  - línea base sin mejoras
  - punto de comparación
  - modelo con rendimiento aceptable
- **Normalización (0.87)**
  - técnica con mayor mejora
  - se interpreta como reductor de ruido
  - mejora consistencia del lenguaje y es la más efectiva
- **Sin Stopwords (0.74)**
  - mejora leve respecto a la original
  - elimina palabras vacías pero sin determinación
  - elimina el contexto de algunas tareas de intención
- **Lematización (0.61)**
  - Rendimiento decaído
  - elimina información útil afectando el término clave
  - visto en dominios técnicos
- **Todos combinados (0.74)**
  - no supera la versión normal
  - mismo rendimiento que sin stopwords
  - puede causar sobreprocesamiento

Visualizaciones complementarias

Como el origen de gran parte de la información proviene de fuentes mixtas, es una buena práctica incluir visualizaciones complementarias a la información ya obtenida, a continuación se incluyen ciertos diagramas generados

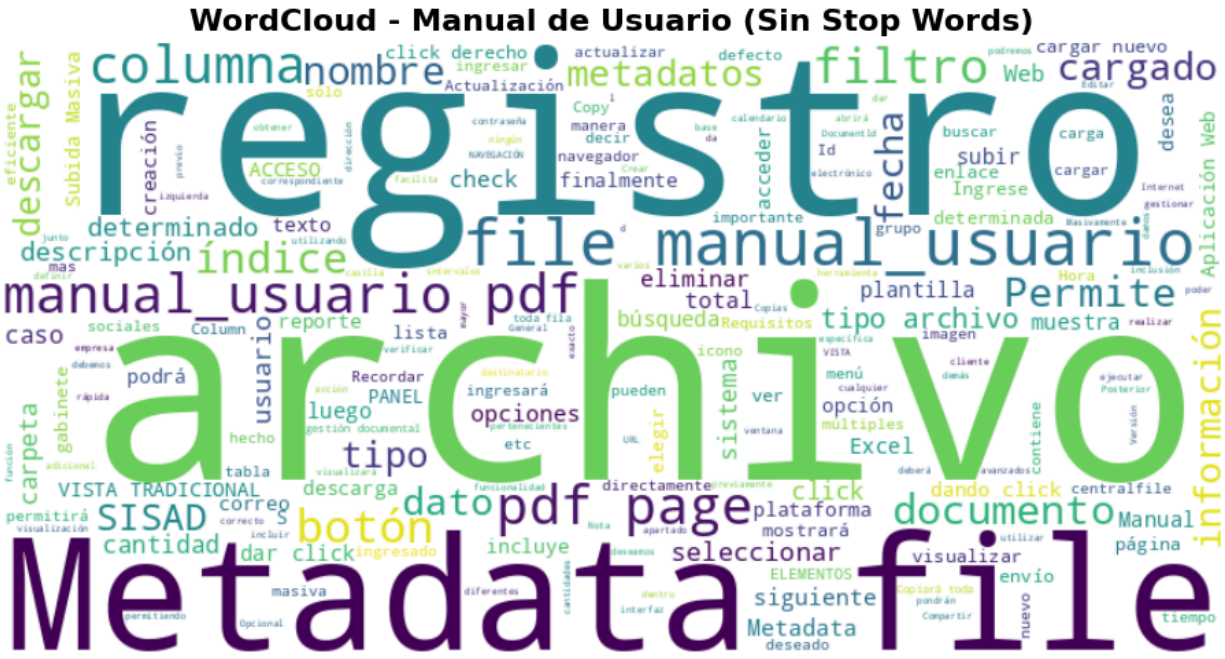

WordCloud - Manual de Usuario (Sin Stop Words)

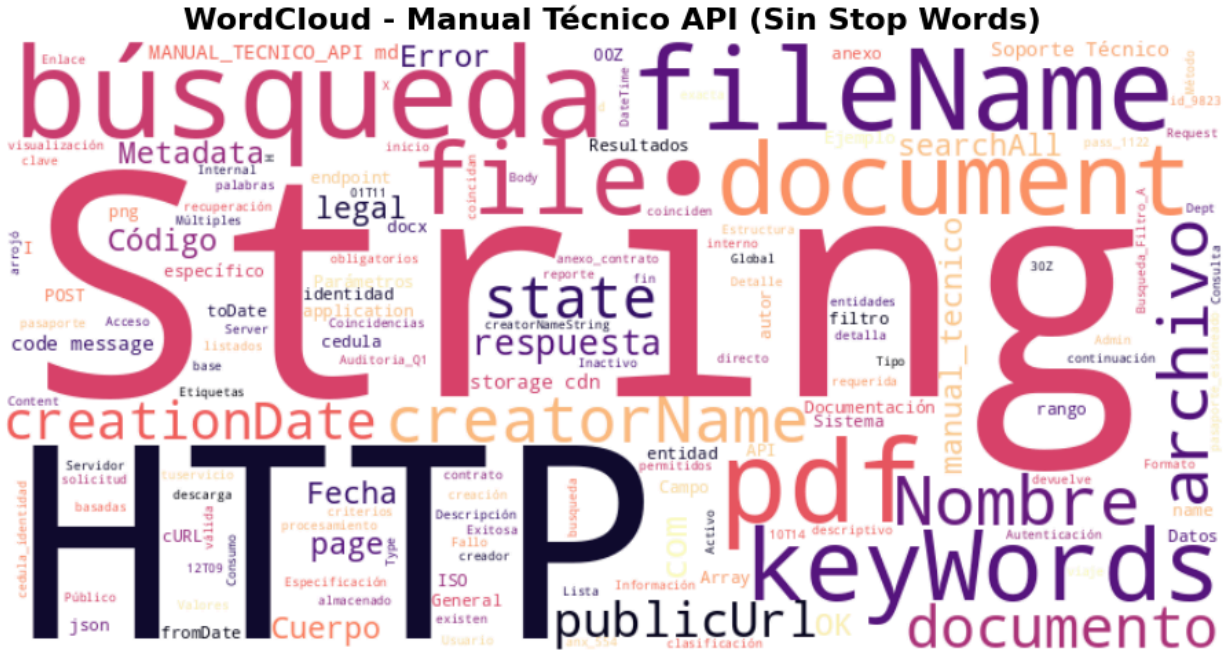

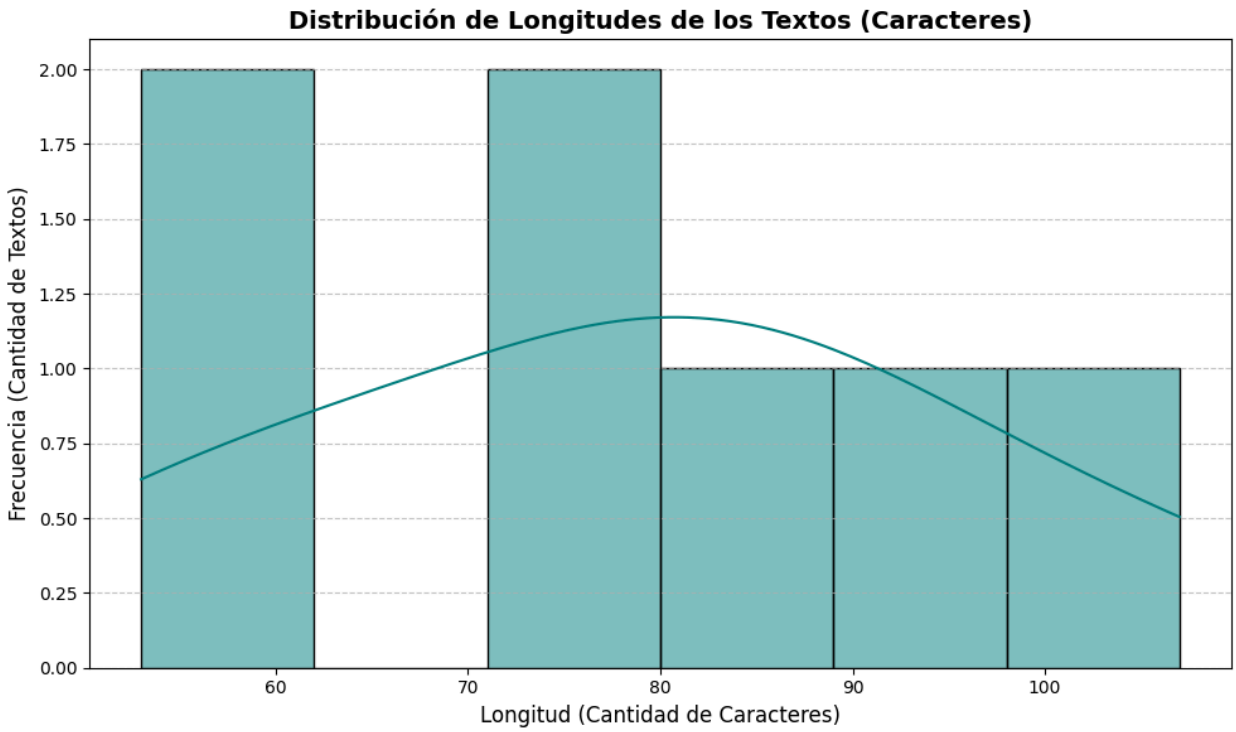

Detección de valores atípicos (outliers).

Método: Se utilizó el **Rango Intercuartílico (IQR)** sobre la longitud de caracteres.

Justificación: Frases con una longitud superior a **Q3 + 1.5 * IQR** fueron analizadas; se mantuvieron aquellas que aportan contexto semántico y se descartaron las que eran cadenas de texto aleatorias o errores de log.

Google API, este modelo se destaca significativamente como el de mayor rendimiento. Con un Accuracy (WRR) del 97.78% y un F1-score del 97.78%, superó a todos los demás modelos por un margen considerable. Esto indica que la API de Google logró la transcripción más precisa de los audios de prueba, con muy pocos errores. Whisper (tiny), outlier de bajo rendimiento en esta configuración específica, en el otro extremo, la versión tiny de Whisper mostró el rendimiento más bajo entre los modelos evaluados, con un Accuracy (WRR) del 86.67% y un F1-score del 87.64%. Si bien Whisper es un modelo muy potente en general, esta versión "tiny particular" no se desempeñó tan bien en este conjunto de pruebas específico en comparación con los otros modelos, cometiendo más errores de inserción y sustitución.

Referencias bibliográficas

- To‘xtasinov, A. I., & Sodiqov, V. S. (2025). The importance of data cleaning in data analysis. Journal of New Century Innovations, 78(2), 115–117. https://scientific-jl.com/new/article/view/19541
- Purohit, K. (2021). Separation of data cleansing concept from EDA. International Journal of Data Science and Analysis, 7(3), 89–97. https://doi.org/10.11648/j.ijdsa.20210703.16
- Schelter, S., et al. (2022). Data cleaning and AutoML: Would an optimizer choose to clean? Datenbank-Spektrum, 22, 1–14. https://doi.org/10.1007/s13222-022-00413-2