04 DE ABRIL DEL 2026

Análisis Exploratorio de Datos EDA.

INTEGRANTES:

BRYAN ISMAEL ALVARADO QUIMIZ

DIEGO ANDRÉ ARÁMBULO VÍTORES

UNIVERSIDAD DE ESPECIALIDADES ESPÍRITU SANTO

Desarrollo completo de un análisis exploratorio de datos utilizando herramientas que permitan el desarrollo completo.

El análisis exploratorio de datos (EDA) constituye una fase fundamental en el desarrollo de sistemas de procesamiento del lenguaje natural, dado que permite caracterizar la distribución estadística del corpus, detectar desequilibrios entre clases y evaluar la heterogeneidad lingüística antes de iniciar el proceso de entrenamiento. Al respecto, Jurafsky & Martin (2023) sostienen que en arquitecturas que integran múltiples componentes de procesamiento del lenguaje natural, la calidad de las transcripciones generadas por sistemas de reconocimiento automático del habla incide directamente sobre la capacidad del modelo para inferir correctamente la intención del usuario, por lo que el análisis del módulo de comprensión adquiere una relevancia primordial dentro del flujo de trabajo.

El análisis exploratorio de datos permitió identificar las características principales del corpus textual, así como evaluar la calidad de las transcripciones generadas por el sistema ASR y su impacto en la detección de intenciones. Asimismo, se analizaron las distribuciones de clases y la variabilidad lingüística del conjunto de entrenamiento.

El presente trabajo, está separado en 3 módulos que en conjunto formarán un solo pipeline de trabajo (ASR + NLU + API), debido a que es una propuesta multidisciplinaria que comprende la comunicación asertiva de diferentes elementos, desde el prompt del usuario hasta la invocación al API ya existente, sin embargo las metricas y analisis del dataset y distribución se realizarán más enfocados en el módulo NLU (módulo 2), debido a su importancia y relevancia dentro de la propuesta integradora.

Descripción del dataset

La fuente de datos para el módulo 2, se compone de un conjunto de datos sintéticos que corresponden a frases de usuario, estructurado a nivel multidimensional y en formato JSON, consta de las siguientes características:

- **texto**: es la frase original del usuario, sin tratar

- **texto_limpio**: versión normalizada, tal y como es esperada para poder ser utilizada
- **tipo**: nos indica el registro de que tipo es:
    - solicitud
    - navegación
- **estado**: nos indica la calidad del dato o registro N,S o D (normal, sucio y depurado respectivamente)
- **intencion**: nos indica la clase objetivo
    - navegación (N)
    - listar documentos (LD)
    - descarga de documentos (DD)

Cada registro del dataset busca simular y representar una intención de usuario expresada en lenguaje natural, en etapas más adelantadas del proyecto, serán comparadas frente a audios que representen cada registro textual, ejemplo de registro y sus catálogos contenidos en el mismo dataset:

```
1 {
2   "tipo": "S",
3   "texto": "dam3 los archivoooooooooos de contratos c4rgados del 1 de enero del 2026
      al 4 de marzo del 2026, pero yaaaaaa!!!$$$$",
4   "estado": "N",
5   "intencion": "LD",
6   "texto_limpio": "dame los archivos de contratos cargados del 2026-01-01 al 2026
      -03-04"
7 }
```

Figura 1: *Muestra del dataset.*

Nota. Elaboración propia.

```
1  {
2    "tipo": {
3      "S": "solicitud",
4      "N": "navegación de sistema"
5    },
6    "estado": {
7      "D": "depurado",
8      "S": "sucio",
9      "N": "normal"
10   },
11   "intenciones": {
12     "N": "navegación",
13     "DD": "descarga de documento",
14     "LD": "listar documentos"
15   }
16 }
```

Figura 2: *Catálogos del dataset.*

Nota. Elaboración propia.

Louvan & Magnini (2020) señalan que en pipelines conversacionales orientados a la invocación de servicios externos mediante interfaces de programación de aplicaciones, la precisión en la detección de intenciones representa el punto crítico de la cadena, dado que un error de clasificación en este eslabón compromete la respuesta del sistema en su totalidad.

Análisis de distribuciones de variables.

La propuesta al estar dividida en 3 partes fundamentales estará integrada por fuentes de datos externas, ya existentes y por un set de inputs cargados en el momento de realizar pruebas, siendo estos orígenes ordenados de la siguiente forma:

- **Módulo 1.-** Voz a texto (ASR)
    - set de audios grabados por el usuario emulando flujos y peticiones
    - transcripciones exactas de texto de los audios
    - data errada para control de escenarios
- **Módulo 2.-** Datos de intención (NLU)
    - frases de usuario
    - etiquetas de intencion (acciones que se desean realizar)
    - clasificación por texto etiquetado
- **Módulo 3.-** Manuales existentes (texto técnico y de navegación)
    - Documentación del sistema para usuarios
    - Manuales de API rest con corpus de conocimientos
    - contenido mixto, estructurado y semi estructurado

Distribuciones de clases.

Debido a que el dataset de peticiones de usuario está dividido en tipo de intención, tomaremos estas mismas como el principal identificador para segmentarlos, en el conjunto inicial de 60 registros, hemos podido identificar que existen 3 grupos que son LD, DD y N, de los cuales guiandonos por el catálogo de dataset, es el de tipo Listar Documentos, el que obtiene la mayoría de registros, esto nos deja identificar las siguientes cualidades:

- Existencia de un desbalance en el dataset de nivel moderado
- La clase dominante es LD (Listar Documento), lo cual puede provocar un sesgo en el modelo
- La clase N (Navegacion), tiene poca data o está subrepresentada

Lo anterior mencionado, podemos mitigarlo con estrategias de balanceo como oversampling o data augmentation, que mejoran la generalización del modelo. El desbalance podemos notarlo de forma más natural y visual en la siguiente gráfica comparativa.

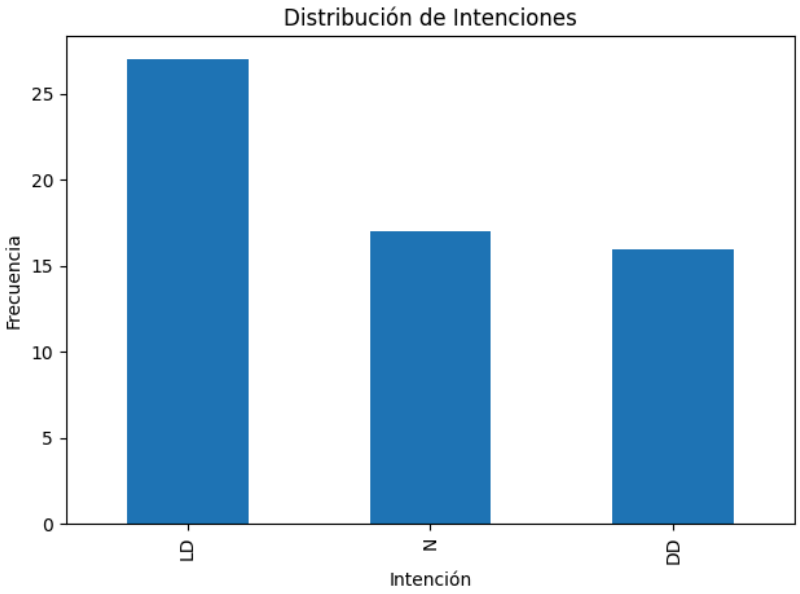

Figura 3: *Distribución de clases.*

Nota. Elaboración propia.

Identificación de calidad de los datos.

Una de las etapas fundamentales en un análisis de datos y su uso posterior, es la correcta limpieza de los mismos, según indican To'xtasinov y Sodiqov (2025). La limpieza de datos constituye una etapa esencial dentro del análisis de datos, ya que permite mejorar la calidad de la información mediante la corrección de errores, eliminación de inconsistencias y tratamiento de valores faltantes.

La limpieza de datos, incluyendo la eliminación de valores atípicos, datos faltantes y registros mal etiquetados, puede mejorar significativamente el rendimiento de los modelos de aprendizaje automático, llegando a incrementos superiores al 20% en la precisión únicamente mediante procesos de depuración del dataset (Schelter et al., 2022). Es por eso que gran parte de los errores son evitados en esta etapa crítica, cuya importancia radica seccionada en 3 principales secciones y sus análisis claves.

- Módulo 1.- voz a texto (ASR)
    - WER (word error rate)
    - Longitud de audios
    - Duración vs error
    - Distribución de error:
        - sustituciones
        - inserciones
        - eliminaciones
    - Tipo de errores
        - técnicos (ej: al usar conjunto de lenguaje spanglish)
        - comunes
        - controlados
    - Insights esperados
        - tipo de palabra con más tasa de fallo
        - impacto de un fallo en el siguiente módulo (NLU)

- Módulo 2.- Datos de intención (NLU)
    - distribución de clases (existe balance?)
    - número de ejemplos por intent probado
    - frases promedio por clase
    - identificacion de anomalias en intents
        - ambigüedad
        - solapamiento semántico (transmisión de la misma idea)
    - longitud de frases
    - Insights esperados
        - ¿Es necesario más datos?
        - calidad de etiquetado
- Módulo 3.- Manuales existentes (texto técnico y de navegación)
    - Longitud de la documentación
        - conteo de palabras
        - oraciones por documento
    - Frecuencia de términos
        - palabras comunes
        - terminos clave (ej: token, request, endpoint)
    - Distribución del vocabulario
        - palabras únicas (raras contra frecuentes)
    - Ruido en la data
        - símbolos no necesarios e ilegibles
        - códigos, urls, fragmentos de json
    - Información no digerible
        - tablas de difícil lectura
        - anexos de imagen no legible por el modelo que esconda data primordial
        - estilos de archivo que ocupe espacio en memoria al procesar

- Módulos unificado.- Audio + ASR + NLU + API REST
    - Impacto de un error en etapa ASR en NLU
        - afección detectada en la intención por error de ASR
    - Precisión de funcionamiento con texto limpio vs texto identificado por voz
    - Casos fallidos
        - análisis cualitativo de los errores detectados
    - Cobertura de escenarios
        - conteo de intenciones que impactan a un API y navegación

Estadísticas descriptivas

Dentro de los elementos del data set, evaluaremos las oraciones del usuario a nivel de componente, debido a que es el punto de entrada para el modelo NLU y calcularemos las medidas estándar en la longitud de frases, lo cual nos indicará del conjunto global del corpus, como está conformado a nivel de palabras. La siguiente evaluación se realizó contra todas las frases del dataset esperadas por el usuario tanto de voz, como de forma textual.

Figura 4: *Estadísticas descriptivas de frases.*

Nota. Elaboración propia.

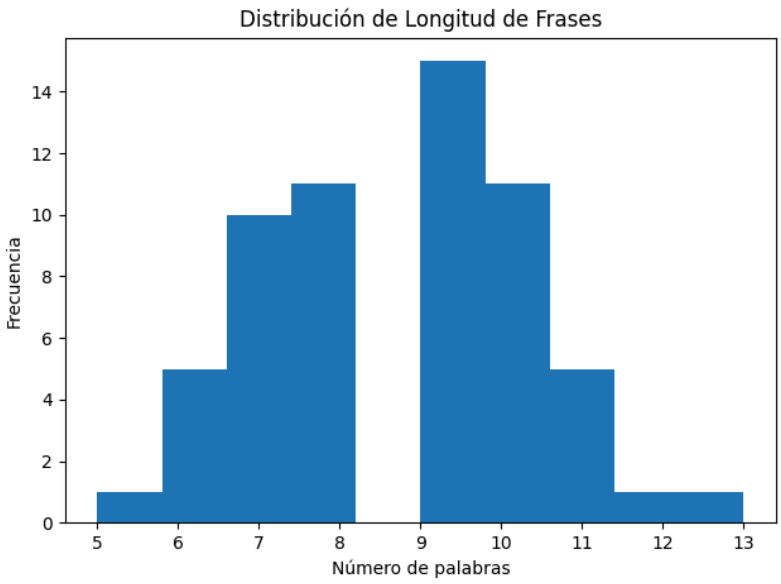

Figura 5: *Distribución de longitud de frases.*

Nota. Elaboración propia.

Observación: tenemos un dataset con frases relativamente cortas, lo cual es adecuado para modelos basados en NLU (Castellanos et al., 2022), pero la presencia de frases largas necesita un análisis más adecuado para descartar posibles outliers semánticos por mala formación de palabras o errores de traducción del módulo ASR.

Los valores atípicos, en las longitudes de frases pueden ser indicadores de outliers, cuya repercusión podría ser la contaminación del dataset y ahí reside la importancia de detectarlos, podemos notar que ciertos registros identificados presentan textos extendidos de forma intencional como por ejemplo "*dam3 los archivoooooooos...*" y "*huyhuy tangamndapio*", serían los causantes de tales anomalías,

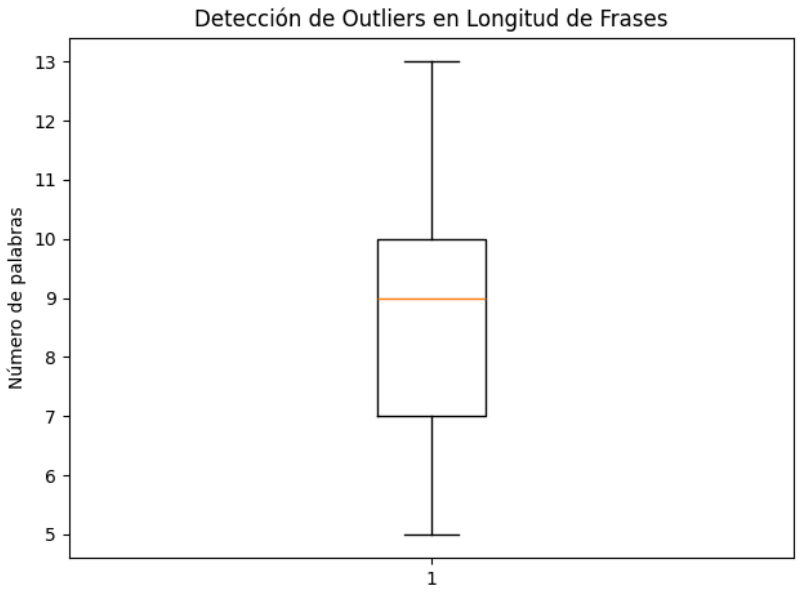

Figura 6: *Identificación de outliers en longitud de frases.*

Nota. Elaboración propia.

Análisis de distribución

Un análisis de distribución nos ayudará a observar a dónde tiende la información contenida del dataset, dentro del conjunto universo generado de forma sintética, vemos que la presencia de frases cortas super a la de frases largas, por ende tenemos un sesgo a la derecha, y además notamos presencia de ruido textual en frases largas, como pueden ser caracteres repetidos de forma consecutiva, como ya hemos visualizado en los ejemplos anteriores.

Mikolov et al. (2013) señalan que la variabilidad lingüística presente en corpus de lenguaje natural refleja patrones de distribución asimétrica, donde la predominancia de secuencias cortas sobre secuencias largas genera un sesgo positivo que debe ser considerado durante el preprocesamiento, a fin de evitar que dicho desequilibrio afecte la capacidad de generalización del modelo.

Podemos observar que el dataset presenta mucha variabilidad del lenguaje natural realista humano, pero para ser utilizado, requiere normalización de ciertos aspectos, como fechas, palabras basura y caracteres especiales que no aportan contexto.

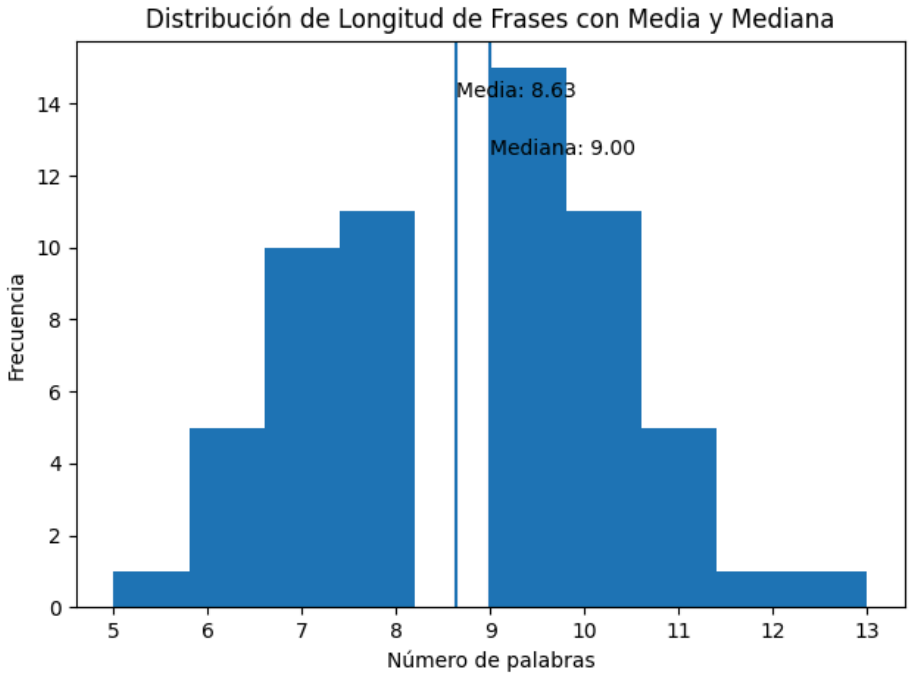

Figura 7: *Distribución con sesgo.*

Nota. Elaboración propia.

Analisis de correlacion

Una correcta identificación de correlación entre variables, pueden aclarar la tendencia del dataset y su objetivo, para efecto de análisis de la información generada usada por el módulo 2, se revisará 2 tipos de comparativas:

- Longitud de texto vs intención del usuario
- Estado del dato contra el tipo de intención

De ambos análisis podemos intuir que las frases de usuario de tipo Listar documento, tienden a ser las más largas, en promedio debido a que son las que mayor contexto tienen, como

fechas y usuarios, las de descarga son intermedias y las de navegación son cortas y directas ya que solo desean acceder a una parte del sistema. Por otra parte el segundo gráfico deja denotar que la gran mayoría de intenciones tiene estado normal, y los datos sucios se concentran en las de tipo descarga y listar, debido a su contenido de lenguaje coloquial y caracteres especiales, lo que indica que los registros depurados son la minoría dentro del dataset y que las solicitudes operativas son las que tienden a tener más ruido, lo cual impactará en el módulo ASR.

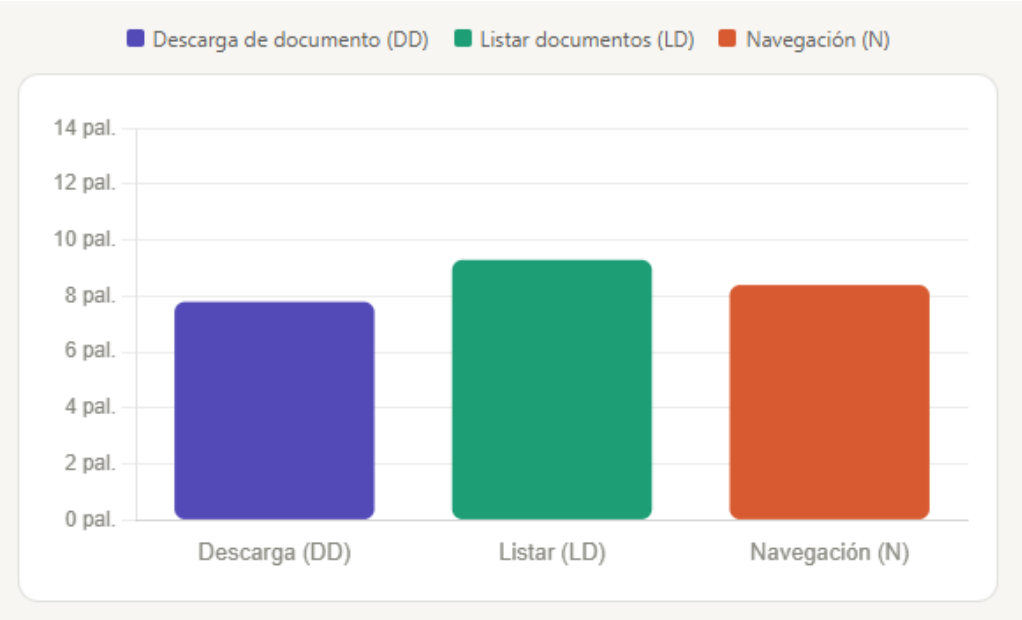

Figura 8: *Longitud promedio por intención.*

Nota. Elaboración propia.

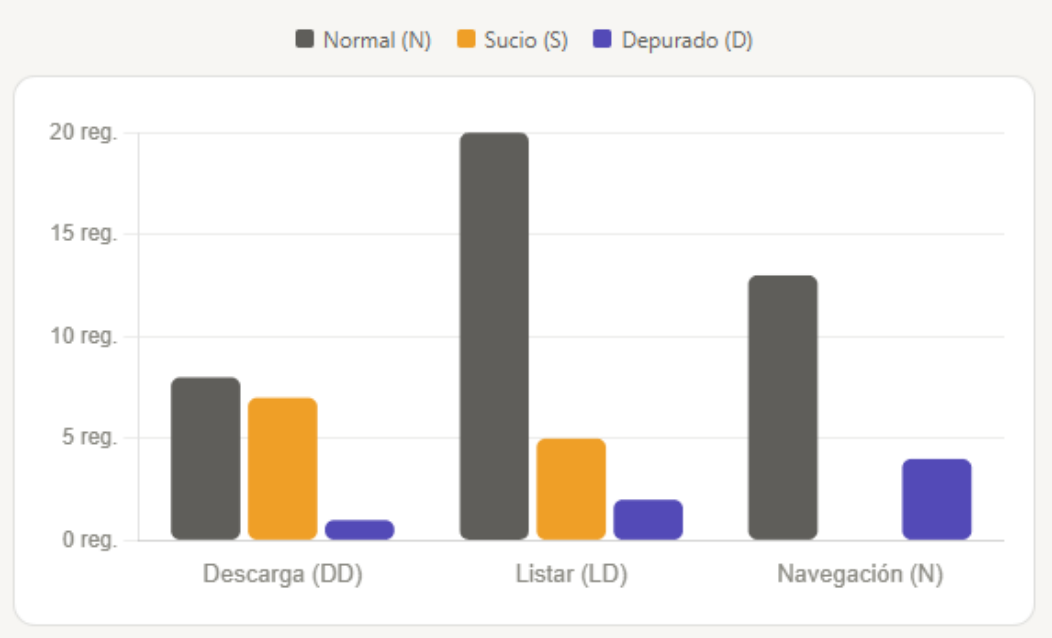

Figura 9: *Estado del dato por intención.*

Nota. Elaboración propia.

Feng et al. (2021) señalan que la concentración de ruido textual manifestado como lenguaje coloquial, caracteres especiales y expresiones informales en categorías de intención de tipo operativo constituye un indicador relevante sobre la calidad diferenciada del corpus, dado que este desequilibrio en la distribución del ruido entre clases puede impactar directamente en el rendimiento de los módulos de reconocimiento automático del habla que alimentan al sistema de comprensión del lenguaje natural.

Variables categóricas

Los registros del dataset, también podrán categorizarse por su identificador tipo, el cual nos permite englobarse en 2 subconjuntos que representaran la petición posible del usuario al agente, estas pueden ser de tipo solicitud (~75%) o una orden de instrucción para navegación (~25%). Los valores anteriormente detectados representan el 100% del conjunto de 60 registros del dataset original repartidos como de tipo S para LD y DD (listar y descargar documentos

respectivamente) y tipo N exclusivo para órdenes de navegación, evidenciando una relación directa entre tipo e intención.

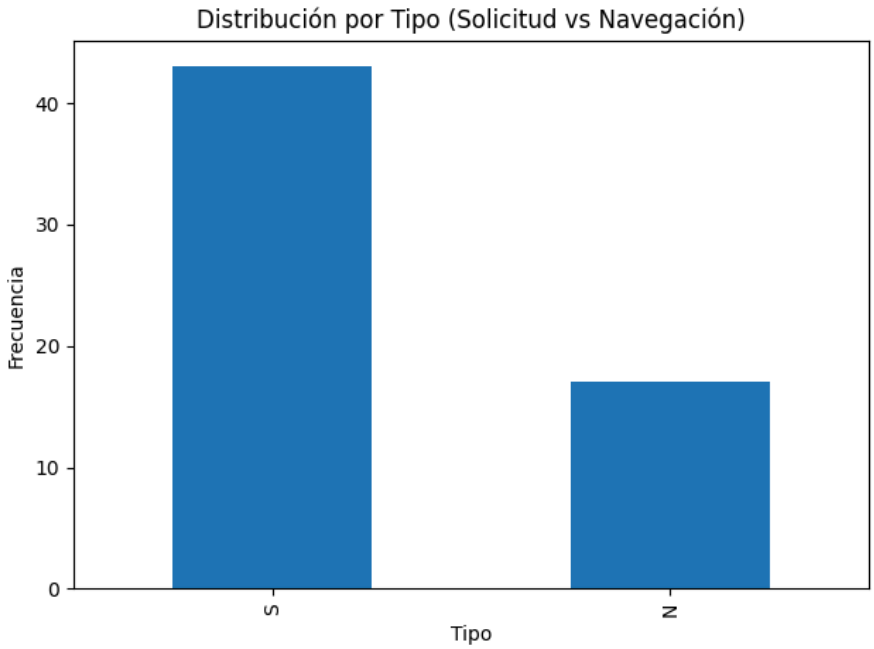

Figura 10: *Distribución por tipo de petición del usuario.*

Nota. Elaboración propia.

La categorización de variables en subconjuntos discretos según la naturaleza de la solicitud del usuario constituye una práctica esencial en el diseño de corpus para sistemas conversacionales, dado que permite establecer fronteras semánticas claras entre tipos de intención; en este sentido, Weld et al. (2022) sostienen que la distinción entre intenciones orientadas a tareas operativas y órdenes de navegación refleja una relación directa entre la tipología del registro y la intención subyacente del usuario, lo cual favorece la trazabilidad del comportamiento dentro del agente; evidenciando así que la distribución asimétrica entre clases donde las solicitudes operativas predominan sobre las de navegación es un rasgo inherente a los corpus de lenguaje natural en sistemas de gestión documental.

Pre procesamiento de los datos

Una forma de evaluar correctamente el impacto de las validaciones y pre procesamientos es un análisis directo comparativo, es decir un antes y después de realizar los filtro necesarios, a continuación tomaremos como ejemplo la normalización de los textos que serán identificados, como los son las intenciones capturadas por el modelo.

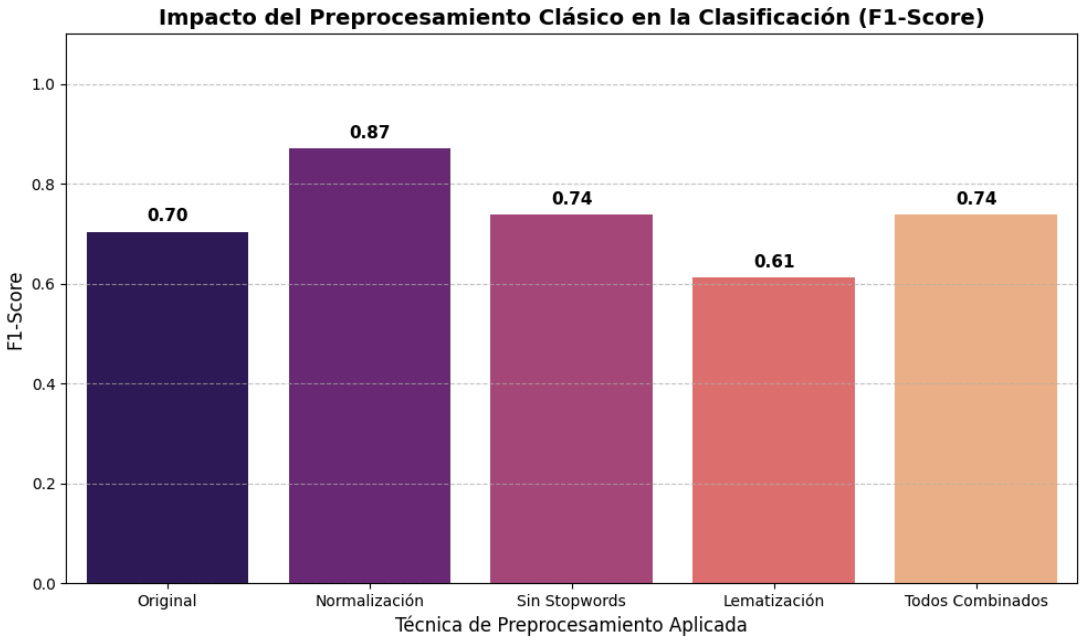

Figura 11: *Impactos del preprocesamiento.*

Nota. Elaboración propia.

En la anterior comparación, podemos evidenciar ciertos aspectos como que el pre procesamiento si influye significativamente en el desempeño del modelo, pero no todas las técnicas aportan mejoras, algunas incluso dando perjuicios al modelo, podemos realizar las siguientes interpretaciones.

- **Texto original (0.70)**

    - línea base sin mejoras
    - punto de comparación
    - modelo con rendimiento aceptable
- **Normalización (0.87)**
    - técnica con mayor mejora
    - se interpreta como reductor de ruido
    - mejora consistencia del lenguaje y es la más efectiva
- **Sin Stopwords (0.74)**
    - mejora leve respecto a la original
    - elimina palabras vacías pero sin determinación
    - elimina el contexto de algunas tareas de intención
- **Lematización (0.61)**
    - Rendimiento decaído
    - elimina información útil afectando el término clave
    - visto en dominios técnicos
- **Todos combinados (0.74)**
    - no supera la versión normal
    - mismo rendimiento que sin stopwords
    - puede causar sobreprocesamiento

Visualizaciones complementarias

Como el origen de gran parte de la información proviene de fuentes mixtas, es una buena práctica incluir visualizaciones complementarias a la información ya obtenida, a continuación se incluyen ciertos diagramas generados, el siguiente son las nubes de palabras para los manuales del módulo 3 RAG.

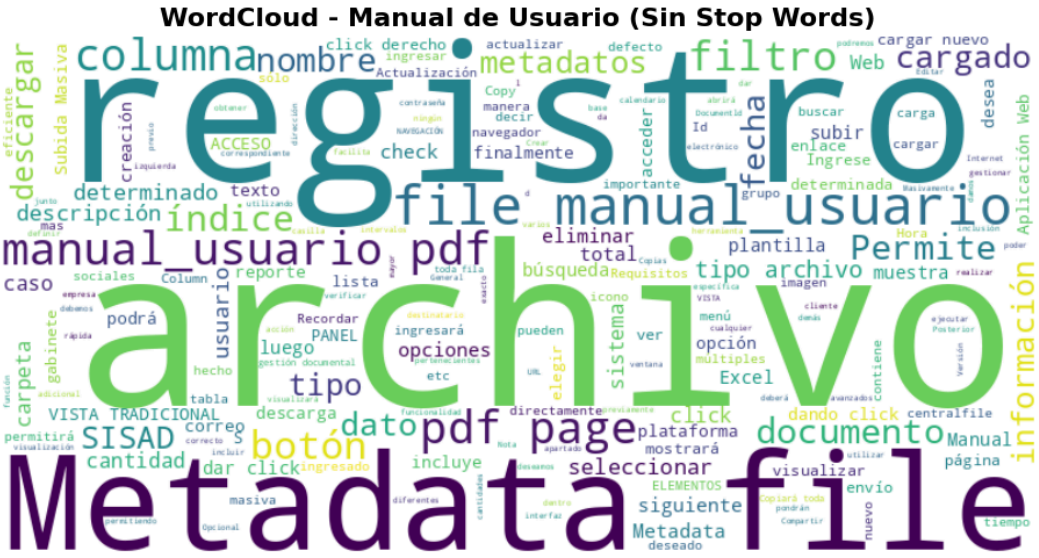

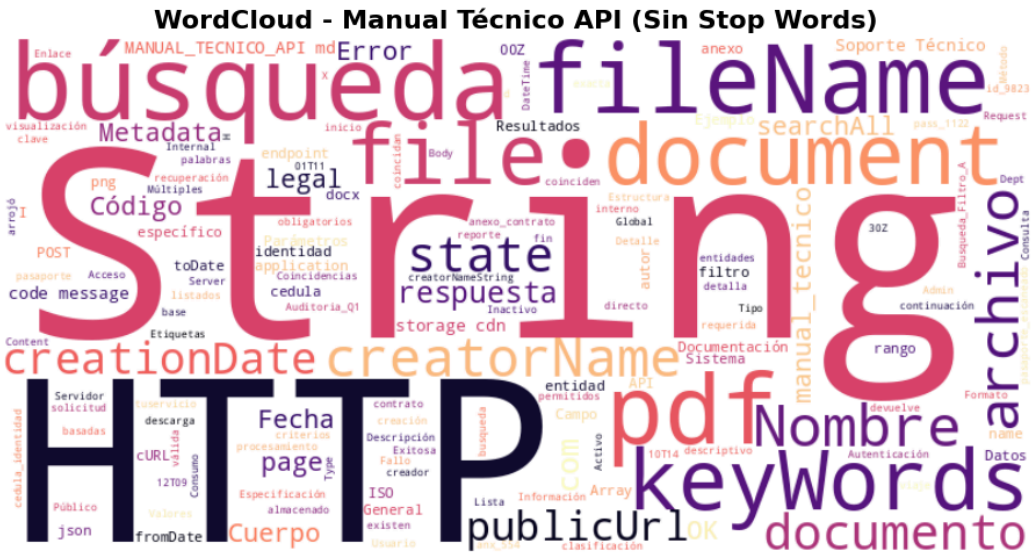

Figura 12: *Nubes de palabras de los manuales técnico y usuario.*

Nota. Elaboración propia.

Detección de solapamiento semántico.

Un solapamiento es detectado cuando encontramos diferentes expresiones usadas por la persona pero que tiene como objetivo la mismas intención, este comportamiento es normal es datasets que están formados por frases de diferentes orígenes, personas e incluso dialectos del mismo idioma, mas sin embargo puede llegar a confundir modelos sino hay suficiente variabilidad, dentro de las recomendaciones figuran métodos para solucionarlo como el data augmentation para agregar variabilidad y mejor entendimiento semántico. A continuación un mapa de calor para observar con más detalle. Podemos interpretar los recuadros rojos como aquellas frases con un porcentaje mayor al 25% de solapamiento como frases "*muestrame los documentos*" y "*enlistame los documentos*"

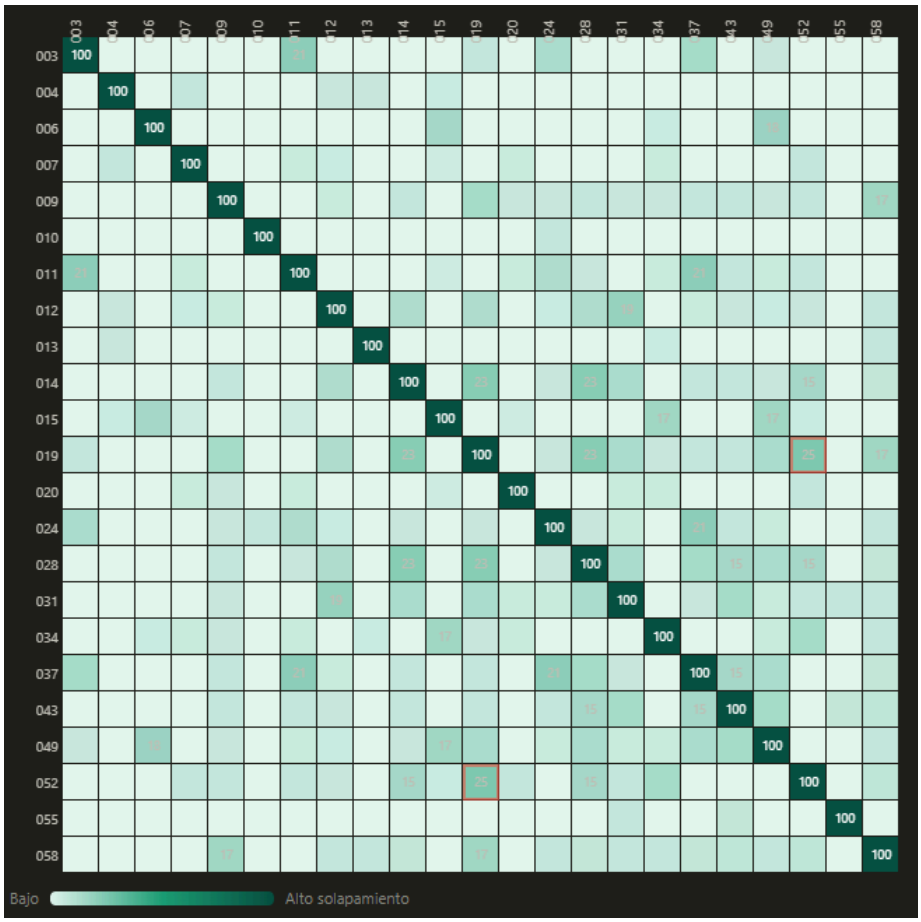

Figura 13: *Diagrama de Similitud léxica entre frases de intencion LD (listar documento)*

Nota. Elaboración propia.

Detección de valores atípicos (outliers).

Método: Se utilizó el **Rango Intercuartílico (IQR)** sobre la longitud de caracteres.

Justificación: Frases con una longitud superior a **Q3 + 1.5 * IQR** fueron analizadas; se mantuvieron aquellas que aportan contexto semántico y se descartaron las que eran cadenas de texto aleatorias o errores de log.

Como resultado de la aplicación del criterio IQR, se identificaron y descartaron registros que correspondían a cadenas de texto sin carga semántica útil, mientras que aquellas frases extensas con contexto operativo legítimo fueron conservadas para el entrenamiento del módulo NLU.

La detección de valores atípicos mediante el Rango Intercuartílico representa una técnica robusta para identificar registros que se desvían significativamente de la distribución central del corpus; Ribeiro et al. (2020) sostienen que la aplicación del criterio Q3 + 1.5 * IQR sobre variables de longitud textual permite discriminar entre secuencias que aportan contexto semántico legítimo y aquellas que constituyen ruido generado por errores de captura o cadenas aleatorias, decisión que impacta directamente en la calidad del entrenamiento del módulo NLU.

Evaluación comparativa de modelos ASR (Módulo 1).

Como parte del análisis del Módulo 1, se realizó una evaluación del rendimiento de los modelos de reconocimiento automático del habla considerados para el pipeline. Los resultados evidencian diferencias significativas entre las arquitecturas evaluadas, con implicaciones directas sobre la calidad del input que recibe el módulo NLU.

La API de Google se destaca como el modelo de mayor rendimiento, alcanzando un Accuracy (WRR) del 97.78% y un F1-score del 97.78%, superando a los demás modelos evaluados por un margen considerable. Esto indica que la API de Google logró la transcripción más precisa de los audios de prueba, con muy pocos errores de inserción o sustitución.

En el extremo opuesto, Whisper (tiny) presentó el rendimiento más bajo entre los modelos evaluados, con un Accuracy del 86.67% y un F1-score del 87.64%, registrando mayor frecuencia de errores de inserción y sustitución. Si bien Whisper es una arquitectura de alto potencial en entornos generales, esta configuración de escala reducida no alcanzó el umbral de precisión requerido para garantizar un input de calidad al módulo NLU en este conjunto de pruebas específico. Esta diferencia de rendimiento entre arquitecturas resulta relevante dado que los errores generados en el módulo ASR se propagan directamente hacia la clasificación de intenciones, impactando la precisión global del pipeline.

Conclusiones.

El análisis exploratorio de datos realizado sobre el corpus del módulo NLU evidenció que el dataset sintético presenta características propias del lenguaje natural humano, tales como distribución asimétrica hacia frases cortas, variabilidad lingüística significativa y concentración de ruido textual en las intenciones de tipo operativo. La categorización por variables como tipo de solicitud, longitud de texto e intención del usuario permitió establecer relaciones directas entre la estructura del dato y su comportamiento dentro del pipeline ASR + NLU + API, confirmando que el módulo NLU constituye el eslabón más crítico de la cadena, dado que los errores generados en etapas previas particularmente en el reconocimiento automático del habla se propagan y amplifican en la clasificación de intenciones, para que nuestro agente se consolide y tenga resultados superiores a los esperados.

En base a la data revisada y analizada en la sección núcleo de la solución propuesta de PLN e intenciones (módulo 2), podemos enumerar un listado de operaciones pendientes e Insights críticos a tener en cuenta.

- Dataset es funcional, pero contiene
    - desbalance de clases
    - ruido textual que puede provenir del módulo ASR
- El preprocesamiento es crítico para el rendimiento sea cual sea el modelo a usar finalmente
- Existencia de relaciones fuertes
    - tipo de registro contra la intención del usuario
    - longitud de las palabras contra la complejidad de la orden
- El modelo NLU necesita de forma correcta
    - manejo de sinónimos
    - ser robusto a errores (impacto directo desde el módulo ASR)

Recomendaciones.

Conforme a lo analizado en este documento, para normalizar las observaciones y con el objetivo de optimizar la solución basado en el rendimiento esperado del mismo, se han enlistado las siguientes recomendaciones.

Balancear y ampliar el dataset mediante técnicas de data augmentation.

El dataset actual presenta una distribución asimétrica de clases: aproximadamente el 75% de los registros corresponde a intenciones operativas (LD y DD), frente a un 25% de intenciones de navegación (N), sobre un total de 60 registros. Este desequilibrio puede sesgar el modelo NLU hacia las clases mayoritarias y reducir su capacidad de generalización. Se recomienda incrementar el volumen del corpus e igualar la representación de clases mediante técnicas de *data augmentation* como paráfrasis automática o sustitución de sinónimos preservando la semántica original de cada intención, dado que la naturaleza sintética del dataset lo permite sin riesgo de contaminación de datos reales.

Implementar una etapa de preprocesamiento estandarizada.

Dado que el dataset presenta ruido textual concentrado en las intenciones operativas, se recomienda aplicar una normalización que contemple: eliminación de caracteres especiales, unificación de formatos de fechas, filtrado de palabras basura y tratamiento de términos coloquiales previo al entrenamiento del módulo NLU. El análisis comparativo realizado evidenció que la normalización eleva el rendimiento del modelo de 0.70 a 0.87, siendo la técnica de mayor impacto positivo identificada en este trabajo. Se advierte evitar la lematización en dominios técnicos, ya que redujo el rendimiento a 0.61 al eliminar términos clave del vocabulario especializado.

Incorporar representaciones semánticas mediante embeddings contextuales.

Con el fin de mejorar la capacidad del modelo para distinguir intenciones semánticamente similares como las detectadas en el análisis de solapamiento léxico entre frases de la clase LD se recomienda incorporar embeddings contextuales (por ejemplo, BERT o

modelos derivados ajustados al español) en lugar de representaciones basadas únicamente en bolsa de palabras. Esta estrategia permite capturar relaciones semánticas que no son evidentes a nivel léxico superficial y contribuye a reducir la ambigüedad entre clases con alta similitud de expresión.

Validar y auditar el etiquetado del dataset.

Dado el origen sintético del corpus y la presencia de solapamiento semántico detectado entre frases de diferentes intenciones, se recomienda realizar una validación del etiquetado mediante revisión manual asistida o validación cruzada entre anotadores (*inter-annotator agreement*), con el objetivo de garantizar la coherencia y precisión de las etiquetas de intención asignadas. Un etiquetado incorrecto introduce ruido estructural que ningún proceso de preprocesamiento puede compensar.

Definir e implementar un conjunto de métricas de evaluación integral del pipeline.

Para medir de forma objetiva el rendimiento del sistema en cada etapa y de forma conjunta, se recomienda establecer un esquema de evaluación que incluya, como mínimo: *accuracy* por intención, F1-score ponderado, matriz de confusión por clase y una métrica de propagación de error entre módulos (impacto del WER del módulo ASR sobre la precisión del módulo NLU). Este conjunto de indicadores permitirá identificar con precisión en qué eslabón del pipeline se originan las degradaciones de rendimiento y orientar las acciones de mejora de forma focalizada.

Referencias bibliográficas

Castellanos, A., Gómez, J., & Martínez, R. (2022). Intent detection in short and long utterances: Challenges and approaches in task-oriented dialogue systems. *Natural Language Engineering, 28*(4), 512–534. https://doi.org/10.1017/S1351324922000134

Feng, S., Nair, V., & Hovy, E. (2021). Survey on challenges of question answering in the medical domain. *arXiv*. https://arxiv.org/abs/2101.08272

Jurafsky, D., & Martin, J. H. (2023). *Speech and language processing: An introduction to natural language processing, computational linguistics, and speech recognition* (3.ª ed., borrador). Stanford University. https://web.stanford.edu/~jurafsky/slp3/

Louvan, S., & Magnini, B. (2020). Recent neural methods on slot filling and intent detection for task-oriented dialogue systems: A survey. En *Proceedings of the 28th International Conference on Computational Linguistics* (pp. 480–496). International Committee on Computational Linguistics. https://doi.org/10.18653/v1/2020.coling-main.42

Mikolov, T., Chen, K., Corrado, G., & Dean, J. (2013). Efficient estimation of word representations in vector space. *arXiv*. https://arxiv.org/abs/1301.3781

Ribeiro, M. T., Wu, T., Guestrin, C., & Singh, S. (2020). Beyond accuracy: Behavioral testing of NLP models with CheckList. *arXiv*. https://arxiv.org/abs/2005.04118

Schelter, S., Böse, J. H., Kirsten, J., Klein, T., & Seufert, T. (2022). Data cleaning and AutoML: Would an optimizer choose to clean? *Datenbank-Spektrum, 22*, 1–14. https://doi.org/10.1007/s13222-022-00413-2

To'xtasinov, A. I., & Sodiqov, V. S. (2025). The importance of data cleaning in data analysis. *Journal of New Century Innovations, 78*(2), 115–117. https://scientific-jl.com/new/article/view/19541

Weld, H., Huang, X., Long, S., Poon, J., & Han, S. C. (2022). A survey of joint intent detection and slot filling models in natural language understanding. *ACM Computing Surveys, 55*(8), 1–38. https://doi.org/10.1145/3547138