Universidad Espíritu Santo

10 DE ABRIL DEL 2026

Preparación y Procesamiento de Datos.

INTEGRANTES:

BRYAN ISMAEL ALVARADO QUIMIZ

DIEGO ANDRÉ ARÁMBULO VÍTORES

UNIVERSIDAD DE ESPECIALIDADES ESPÍRITU SANTO

Preparación y Procesamiento de Datos

En esta fase el objetivo es convertir el texto bruto en un formato estructurado. Dado que no contamos con un dataset externo, el proceso comienza con la generación de un corpus controlado derivado de los diccionarios de intención y entendimiento presentes en el desarrollo del proyecto.

Dada la complejidad estructural del idioma español, el éxito de los modelos de inteligencia artificial depende en gran medida de la uniformidad de los datos de entrada. En este sentido, la normalización lingüística en tareas de Procesamiento de Lenguaje Natural para el idioma español es fundamental debido a la riqueza morfológica y el uso de tildes, lo cual puede generar una dispersión de datos si no se trata adecuadamente en la fase de preparación (Manning et al., 2008). Este proceso donde se realiza estandarización permite reducir la ambigüedad y asegura que las variaciones ortográficas del idioma no afecten la capacidad predictiva del sistema.

Debido a la naturaleza del pipeline de IA, consta de 3 módulos que tienen cada uno su propio dataset, para efecto de practicidad el proceso de procesamiento y limpieza de datos se a separado de la siguiente forma:

- Identificación de intenciones que puede tener el usuario
- Armar un dataset de frases, emulando solicitudes del usuario al sistemas, aproximadamente de 10 a 20 por cada intención detectada.
- Grabación de todas las frases encontradas en dicho dataset para realizar las pruebas del modelo/API ASR
- Para el módulo RAG, se necesitaran 2 manuales, el de usuario que sí existe, y uno generado sintéticamente a partir del contrato de la api rest de búsqueda de archivos, ambos archivos generados en formato Markdown para mayor entendimiento y procesamiento, agregándoles ruido y contenido no deseable fuera de contexto.

Los dataset mencionado con anterioridad, deberán pasar por procesos de filtrado semántico, léxico y de normalización del lenguaje, para ella se elaboró el siguiente plan:

- ASR (Reconocimiento de voz)
    - Obtener muestras de grabaciones reales con distintas voces y tonos
    - Normalización de texto identificado*
- NLP (Identificación de patrones/intenciones)
    - Utilización de vectores de texto para detectar entidades en el contenido textual proveniente del módulo 1, tales como intenciones y usuarios
    - Normalización de texto identificado*
- RAG (sistemas expertos basados en manuales como base conocimiento)
    - Eliminación de contenido repetido o redundante
    - Limpieza de Manuales - Eliminar
        - Data irrelevante (imagenes y tablas)
        - Data duplicada (definiciones y enunciados)
        - Errores de Typo, cadenas de texto sin sentido
        - Data no relacionada al texto (fuera de contexto)
    - Normalización de texto identificado*

(*)La normalización de texto incluye manejo constante de minúsculas, reemplazo de acentos, caracteres extraños, eliminación de redundancia, ajuste semántico y mejoras al manejo de fecha ej: primero de marzo del dos mil veinte y cuatro, se traduce a 2024-03-01

Resultados del EDA.

El análisis exploratorio de datos realizado sobre el corpus del módulo NLU reveló un conjunto de características estructurales que condicionan directamente el desempeño del pipeline propuesto. En primera instancia, se identificó una distribución asimétrica de clases en el dataset de 60 registros, donde la intención de tipo Listar Documentos (LD) concentra la mayoría de los registros, representando aproximadamente el 75% del total junto con la clase Descarga de Documentos (DD), mientras que la clase Navegación (N) se encuentra significativamente subrepresentada con apenas un 25%. Este desequilibrio moderado constituye un factor de riesgo para el entrenamiento del modelo, dado que puede inducir un sesgo sistemático hacia las clases mayoritarias, reduciendo la capacidad de generalización del clasificador frente a intenciones de menor frecuencia (Castellanos et al., 2022). Por ende, el balanceo del corpus mediante técnicas de oversampling dirigido constituyó una intervención prioritaria antes del entrenamiento del modelo

En cuanto a la estructura léxica del corpus, el análisis de estadísticas descriptivas sobre la longitud de frases evidenció que el dataset presenta una distribución con sesgo positivo, caracterizada por la predominancia de secuencias cortas sobre secuencias largas, patrón que Mikolov et al. (2013) asocian con la variabilidad lingüística natural del lenguaje humano y que debe ser considerado durante el preprocesamiento para evitar que afecte la capacidad de generalización del modelo. Asimismo, se detectaron valores atípicos correspondientes a registros con ruido textual intencional como caracteres repetidos consecutivamente y expresiones sin carga semántica los cuales fueron identificados mediante el criterio del Rango Intercuartílico (Q3 + 1.5 * IQR) y tratados de forma diferenciada según su aporte al contexto semántico del corpus (Ribeiro et al., 2020).

El análisis de solapamiento semántico entre frases de la clase LD reveló la presencia de expresiones funcionalmente equivalentes con similitud léxica superior al 25%, tales como *"muéstrame los documentos"* y *"enlístame los documentos"*, fenómeno que puede comprometer la capacidad discriminativa del modelo si no se incorporan técnicas de representación semántica profunda. Al respecto, Weld et al. (2022) sostienen que la distinción entre intenciones semánticamente similares representa uno de los desafíos centrales en sistemas de comprensión del lenguaje natural orientados a tareas, por lo que se recomienda incorporar representaciones contextuales mediante *embeddings* como BERT o modelos derivados ajustados al español, que permitan capturar relaciones semánticas más allá del nivel léxico superficial.

Con respecto a la calidad de los datos, el análisis comparativo de técnicas de preprocesamiento demostró que la normalización textual constituye la intervención de mayor impacto positivo sobre el rendimiento del modelo, elevando la métrica de precisión de 0.70 en su estado original a 0.87 tras su aplicación, lo que representa una mejora del 24.3%. En contraste, técnicas como la lematización redujeron el rendimiento a 0.61, efecto atribuible a la eliminación de términos técnicos relevantes propios del dominio especializado (Schelter et al., 2022). Estos hallazgos confirman que no toda intervención sobre el corpus produce mejoras, y que la selección de técnicas de preprocesamiento debe realizarse de forma selectiva y validada experimentalmente según las características del dominio.

En definitiva, el análisis de correlación entre variables evidenció una relación directa entre el tipo de intención y la longitud promedio de las frases; las intenciones de tipo LD presentan mayor extensión textual debido a que incorporan elementos contextuales como fechas y nombres de usuarios, mientras que las intenciones de navegación tienden a ser cortas y directas. Por otra parte, se constató que el ruido textual se concentra predominantemente en las clases operativas LD y DD, lo cual tiene implicaciones directas sobre el módulo ASR, dado que los errores generados en el reconocimiento automático del habla se propagan y amplifican en la etapa de clasificación de intenciones, comprometiendo la precisión global del pipeline (Feng et al., 2021; Louvan & Magnini, 2020). Por consiguiente, la Tabla 1 sintetiza los hallazgos principales del EDA, organizando cada dimensión analizada junto con su impacto sobre el pipeline y la acción correctiva correspondiente.

Tabla 1 Resumen de hallazgos del Análisis Exploratorio de Datos.

Dimensión analizada	Hallazgo principal	Métrica / Evidencia	Impacto en el pipeline	Acción recomendada
Distribución de clases	Desbalance moderado con sesgo hacia clase LD	LD+DD ≈ 75% / N ≈ 25% sobre 60 registros	Sesgo del modelo hacia clases mayoritarias; baja generalización en clase N.	Data augmentation y oversampling para equilibrar clases.
Longitud de frases	Distribución asimétrica con sesgo positivo.	Media corta predominante; outliers detectados con IQR (Q3 + 1.5 * IQR)	Riesgo de contaminación semántica por registros ruidosos.	Filtrado de outliers y normalización de longitud.
Solapamiento semántico	Similitud léxica > 25% entre frases de clase LD	Pares como "muéstrame los documentos" vs "enlístame los documentos"	Ambigüedad en la clasificación de intenciones.	Incorporación de embeddings contextuales (BERT o similar)
Preprocesamiento	La normalización es la técnica de mayor impacto positivo.	Precisión: 0.70 (base) → 0.87 (normalizado); mejora del 24.3%	Mejora directa en la precisión del módulo NLU.	Aplicar normalización; evitar lematización en dominios técnicos.
Calidad del dato	Ruido textual concentrado en clases operativas (LD y DD)	Lenguaje coloquial, caracteres especiales y expresiones informales.	Degradación del módulo ASR y propagación de errores al NLU.	Etapa de limpieza previa al entrenamiento.
Correlación tipo-intención	Relación directa entre tipo de registro e intención del usuario	Solicitudes (S) → LD y DD; Navegación (N) → exclusivo tipo N	Permite segmentación semántica clara dentro del pipeline.	Mantener la tipología como variable de control en el modelo.
Rendimiento modelos ASR	Diferencia significativa entre arquitecturas evaluadas.	Google API: 97.78% / Whisper tiny: 86.67% (Accuracy WRR)	Errores ASR se propagan directamente al clasificador NLU.	Seleccionar modelo ASR de mayor precisión para producción.
Lematización	Técnica contraproducente en dominios técnicos.	Precisión cae de 0.70 a 0.61 tras aplicación.	Elimina términos clave del vocabulario especializado.	Excluir lematización del pipeline de preprocesamient.

Nota. Elaboración propia.

Pipeline de limpieza de datos.

El módulo 3 (El sistema experto basado en estrategias RAG), debido a su naturaleza, es el más propenso a tener necesidades de ser depurado, esto porque los documentos como manuales de usuario, manuales técnicos, flujos operacionales, diagramas de uso, instructivos en general, son fuentes editadas y mantenidas por personal propenso al fallo, como lo son las faltas ortográficas, fallas semánticas, y contaminación de contenido, es por eso que el módulo indicado recibió una depuración específica en diferentes aspectos en sus corpus, como son:

- Purga de imágenes y tablas, elementos duplicados.
- Datos relevantes al texto y contexto.
- Errores ortográficos y Typos.

El éxito de la arquitectura RAG reside en la calidad en la que se recupera la información, la simplicidad del formato de entrada es determinante al momento de su uso. Los sistemas de generación aumentada por recuperación operan con mejor eficacia sobre archivos de texto plano debido a la ausencia de metadatos complejos y estructuras de formato que suelen introducir ruido semántico durante el proceso de vectorización. Al quitar datos complejos, el modelo de lenguaje se enfoca exclusivamente en el contenido léxico, facilitando una recuperación más precisa de los fragmentos relevantes.

Para la implementación del sistema se optó por el uso de archivos de texto plano, priorizando la simplicidad estructural del conocimiento base. Esta decisión se fundamenta en que la precisión de los sistemas de Generación Aumentada por Recuperación (RAG) depende fundamentalmente de la etapa previa de tratamiento de datos; al transformar archivos con estructuras complicadas en formatos de texto sencillo, se logra disminuir de forma notable las imprecisiones durante la creación de los vectores semánticos (Lewis et al., 2020). Por tanto, la normalización realizada en los documentos de Entendimiento e Intención no es solo estética, sino una optimización del espacio vectorial para que el modelo sea óptimo.

Desde una perspectiva técnica en el desarrollo de sistemas de recuperación de información, Markdown se considera el formato superior para el procesamiento de datos en arquitecturas RAG, debido a su capacidad para estructurar contenido de manera ágil sin perder la jerarquía lógica del documento. A diferencia de los archivos de texto plano convencionales, Markdown permite que el modelo identifique claramente encabezados, tablas y listas, lo cual facilita una segmentación semántica mucho más coherente. Esta estructura simplificada es vital porque la integridad de las representaciones vectoriales en sistemas de recuperación semántica depende de la preservación de la estructura lógica del texto; en este sentido, los formatos ligeros de marcado facilitan una segmentación coherente que minimiza el ruido estructural durante la generación de embeddings (Lewis et al., 2020). Al hacer uso este formato, se garantiza que el contexto recuperado por el modelo sea preciso y mantenga una conexión jerárquica original de la información.

Dentro de las arquitecturas de generación aumentada por recuperación (RAG), la integración de reglas heurísticas opera como un mecanismo de depuración estratégica que elimina contenido irrelevante antes de su procesamiento por el modelo de lenguaje, optimizando así el aprovechamiento de la ventana de contexto. A diferencia de los enfoques basados exclusivamente en similitud vectorial, esta capa lógica adicional permite descartar ruido documental como cláusulas legales, fragmentos truncados o duplicados conservando únicamente los pasajes con valor operativo real. Como señalan Gao et al. (2024), la calidad de la recuperación en sistemas RAG depende críticamente de la fase de preprocesamiento, donde la aplicación de criterios de segmentación y filtrado basado en reglas reduce la contaminación semántica y mejora la precisión de las representaciones vectoriales. Al aplicar criterios heurísticos de purga, se logra una ventana de contexto más limpia, lo que reduce el costo computacional y minimiza la probabilidad de alucinaciones en el modelo generativo.

Ejecutando el pipeline de limpieza sobre los corpus de manual, en este caso técnicos y de usuario, se obtuvieron mejoras significativas en la reducción de ruido y en la extensión lógica de los corpus procesados, según podremos apreciar en la siguiente comparativa.

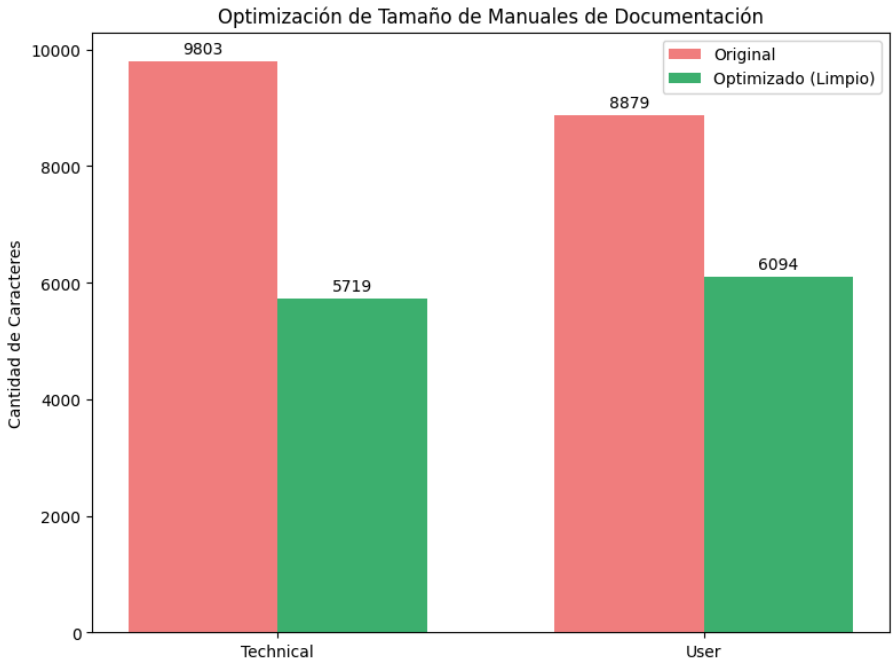

Figura1: *Optimización de Tamaño de Manuales.*

Nota. Elaboración propia.

Feature engineering avanzado.

En tareas de Procesamiento de Lenguaje Natural (PLN), no es suficiente con detectar términos aislados; es necesario construir descriptores que capturen el contexto y la relación entre entidades. Es primordial ya que la normalización lingüística en tareas de PLN para el idioma español es fundamental debido a la riqueza morfológica y el uso de tildes, lo cual puede generar una dispersión de información en la data si no se trata correctamente en la fase de entrenamiento (Manning et al., 2008). Por consiguiente, una ingeniería de atributos robusta actúa como el puente que transforma el lenguaje natural en un conjunto de características numéricas donde las intenciones similares se agrupan y las divergentes se dispersan, minimizando el error en la fase de entrenamiento colaborando con la mejora del mismo.

Dentro del feature engineering, tenemos el caso particular de no poseer variables numéricas normales, sino que trabajamos más con datos cualitativos y entidades detectadas, para lograr nuestro objetivo de evaluar la efectividad de nuestro dataset y análisis de datos, se realizó una comparación directa entre la intención marcada en el dataset de forma sintética (debido a que la data de entrada no existe y debe ser generada a partir de registros similares a los encontrados en el mundo real), y la intención que el pipeline resuelve contra el texto detectado del audio cargado al mismo, este proceso genera una calificación binaria que deriva en un promedio de confianza global del sistema, como se detalla a continuación, la Figura 2 presenta la confianza detectada al comparar textos y la confianza al comparar la intención marcada y los siguientes indicadores.

- **Confianza promedio de texto**: 96.83%
- **Confianza promedio de intención**: 90%
- **Confianza promedio global**: 93.42%

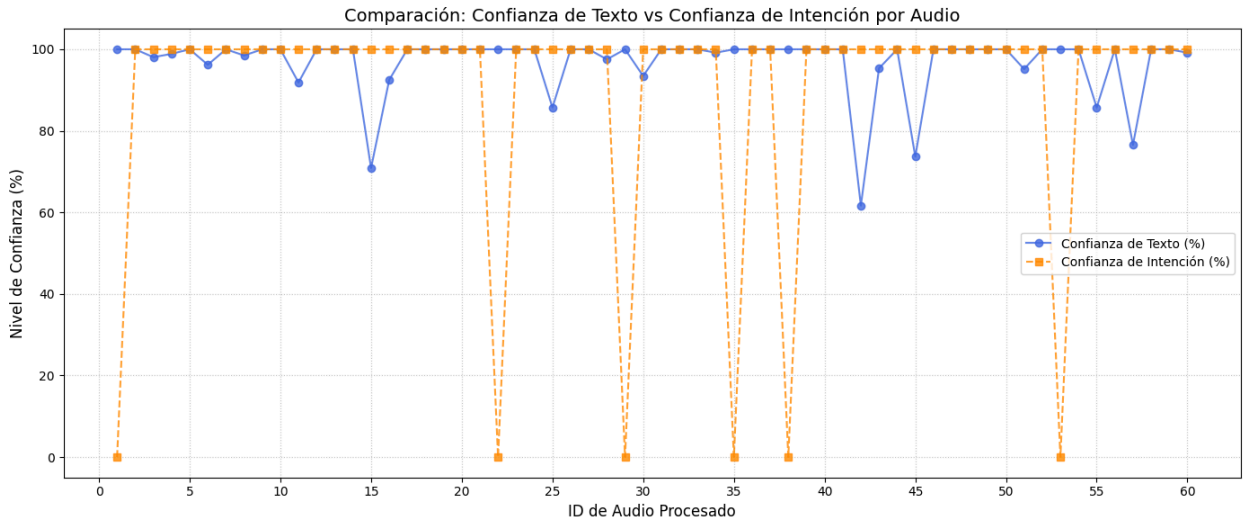

Figura 2: *Confianza de Texto vs Confianza de Interacción.*

Nota. Elaboración propia.

Estrategias de balanceamiento de datos.

Inicialmente el dataset creado manualmente, tenía un desbalance con tendencia y sesgo a registros de tipo LD (Intención de Listar Documentos), esto podría generar que los modelos en caso de ser entrenados, tengan una inclinación sobre el dato mayor entrenado, es por eso que se requiere normalizar y emparejar los registros, como se necesitan solamente igualar la misma población de registros, se usará una técnica simple de Oversampling dirigido, que tendrá como resultado generar más resultado para los otros tipo de intención, DD (Descarga de documento) y N (Navegación), con un total de 21 registros nuevos generados para balancear el dataset, no da un total de 81 items en el corpus del dataset, como se puede apreciar en el diagrama siguiente.

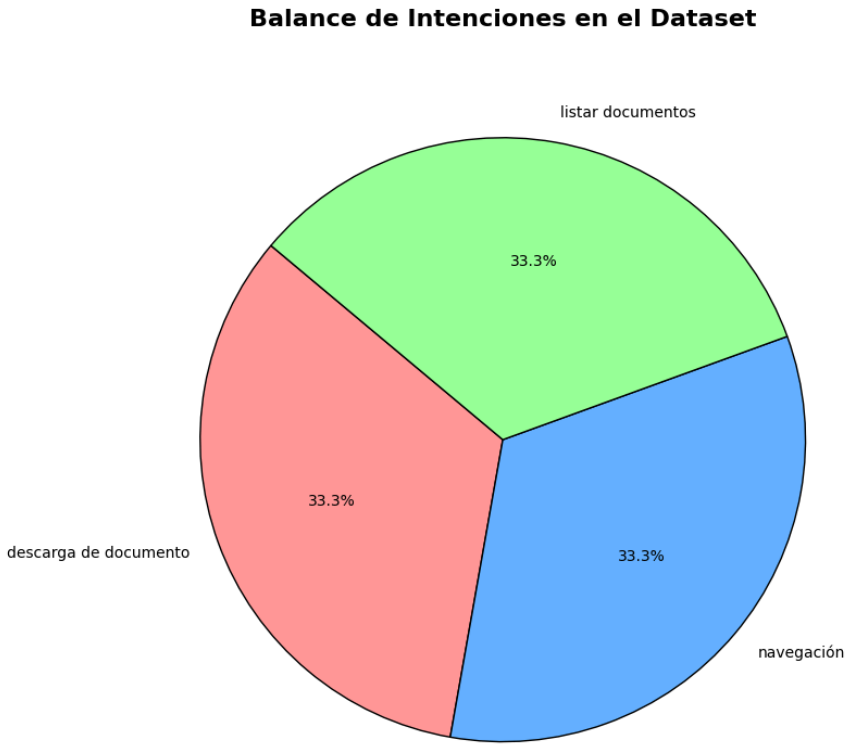

Figura 3: *Balance de intenciones de datos.*

Nota. Elaboración propia.

Cuando un dataset presenta una inclinación desproporcionada, los modelos tienden a optimizar la precisión global a expensas de las clases minoritarias, lo que compromete la capacidad de generalización del sistema. Para contrarrestar este fenómeno, la implementación de técnicas de Oversampling dirigido permite nivelar la representación de las distintas categorías en este caso, las intenciones de descarga y navegación garantizando que el pipeline de aprendizaje cuente con una base comparativa balanceada. Este método es esencial, ya que el equilibrio del dataset mediante técnicas de sobremuestreo no solo mitiga el sesgo hacia las etiquetas dominantes, sino que mejora significativamente la robustez del modelo al proporcionar una exposición uniforme a las características distintivas de cada clase (Kaur et al., 2023). Mitigando la optimización de precisión que el modelo pueda generar.

Técnicas de data augmentation (según el tipo de datos).

Bajo la particularidad del dataset compartido por el módulo 1 y 2, al encontrarse en un desbalance inicial con 30 registros y ser de múltiples dimensiones (texto natural, intención, estado y contexto documental), se decidió usar una combinación entre sustitución de entidades (NER-based) para generar más entidades como nombres, fechas y ciudades, así como también el agregado de Ruido sintético (Noise Injection), ya que en la muestra tenemos escenarios donde los textos contienen uso de caracteres errados, y mala formación de letras (uso de números como vocales, repetición de cadenas de letras, uso de caracteres especiales, etc), siendo ambas técnicas fundamentales, al provenir en ambientes reales de ASR y texto ingresado por usuarios, es decir, es propenso a fallos y errores en su digitación.

En este caso para poder normalizar el dataset principal, fue necesaria la tecnica de insercion de prefijos al principio y fin, básicamente es tomar las existentes minorías y crear variaciones de estas con la implementación de sinónimos en la mayoría de ocasiones, siendo la mejor opción para nuestro dataset porque conserva la semántica, tiene eficiencia computacional y reusa lo que ya sabemos funciona bien (casos reales ya registrados).

En su estudio sobre técnicas de aumento de datos para clasificación de texto, Wei y Zou (2019) evidencian que métodos heurísticos simples, basados en reglas, pueden mejorar significativamente el rendimiento de modelos en conjuntos de datos reducidos, alcanzando resultados similares a enfoques más complejos pero con un menor costo computacional, tras la aplicación del aumento de datos, la Figura 4 evidencia la diferencia entre la distribución de longitud de textos originales y aumentados.

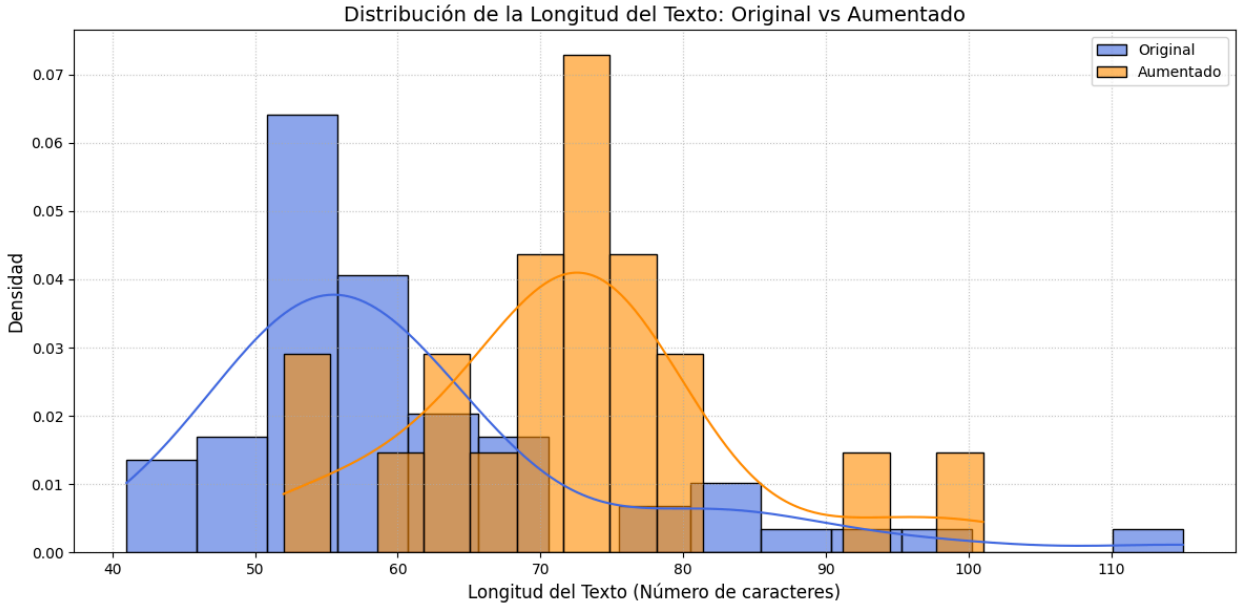

Figura 4: *Distribución de Longitud de Texto.*

Nota. Elaboración propia.

En el entrenamiento de modelos de lenguaje para entornos con datos limitados, NER-based Data Augmentation se presenta como una solución técnica para mitigar el sobreajuste en entornos con escasez de datos. Mediante la sustitución dinámica de entidades por alternativas de la misma categoría semántica o sintáctica, el sistema de detección de intenciones aprende patrones estructurales en lugar de memorizar instancias léxicas específicas. Esta aproximación es fundamental para garantizar la robustez del modelo, ya que la generación controlada de variantes sintéticas permite mantener un rendimiento estable incluso ante entradas con ruido ortográfico, variaciones morfológicas o errores tipográficos (Hu et al., 2023). Como resultado, se fortalece la capacidad de generalización del clasificador, priorizando la identificación de la intención subyacente sobre la dependencia de la superficie textual original.

La capacidad de un pipeline de comprensión de lenguaje natural (NLU) frente a entradas provenientes de sistemas ASR o lenguaje coloquial varía según su capacidad para procesar texto defectuoso. La inyección de ruido sintético permite que el modelo practique en escenarios de falla controlada, simulando errores fonéticos y tipográficos para fortalecer la resiliencia de la detección de intenciones. Este enfoque se fundamenta en que la robustez de un sistema de comprensión de lenguaje natural ante el ruido sintáctico es directamente proporcional a la diversidad de las perturbaciones introducidas durante la fase de preparación de datos (Wei & Zou, 2019). Por ende, para que el pipeline tenga una mayor identificación directa de lenguaje con diferentes términos coloquiales este debe ser expuesto a fallos controlados durante su entrenamiento.

Conclusiones

La fase de preparación y procesamiento de datos constituyó una etapa determinante para garantizar la viabilidad operativa del pipeline propuesto, evidenciando que la calidad del dato de entrada impacta de forma directa y proporcional el rendimiento de cada uno de los tres módulos que conforman la arquitectura ASR + NLU + RAG. Los resultados obtenidos demuestran que ningún módulo puede operar de forma óptima sobre datos crudos sin una intervención estructurada de normalización, limpieza y balanceo previo al entrenamiento.

En el módulo NLU, la aplicación de técnicas de normalización textual representó la intervención de mayor impacto sobre el rendimiento del clasificador de intenciones, elevando la precisión de 0.70 a 0.87, lo que equivale a una mejora del 24.3% respecto al estado base. Este hallazgo confirma que, en dominios especializados con vocabulario técnico, la selección de técnicas de preprocesamiento debe realizarse de forma experimental y selectiva, dado que intervenciones como la lematización demostraron ser contraproducentes al eliminar términos clave del dominio, reduciendo el rendimiento a 0.61 (Schelter et al., 2022; To'xtasinov y Sodiqov, 2025).

El desbalance inicial del corpus, con una concentración del 75% de registros en las clases operativas LD y DD frente al 25% de la clase N, fue corregido mediante la implementación de oversampling dirigido, generando 21 registros adicionales que elevaron el corpus de 60 a 81 instancias balanceadas. Complementariamente, la aplicación de técnicas de data augmentation basadas en sustitución de entidades (NER-based) e inyección de ruido sintético permitió incrementar la variabilidad del corpus, dotando al modelo de mayor robustez frente a entradas defectuosas provenientes del módulo ASR, donde errores fonéticos y tipográficos son inherentes al proceso de transcripción automática del habla (Wei & Zou, 2019; Hu et al., 2023).

En cuanto al módulo RAG, la depuración específica de los corpus documentales mediante la eliminación de imágenes, tablas, duplicados y contenido fuera de contexto y la conversión a formato Markdown demostraron ser decisiones arquitectónicas fundamentales para preservar la jerarquía lógica del documento y minimizar el ruido semántico durante la vectorización. La aplicación de reglas heurísticas de purga optimizó la ventana de contexto disponible, reduciendo el costo computacional y la probabilidad de alucinaciones en el modelo

generativo (Gao et al., 2024). Los resultados finales del pipeline integrado evidenciaron una confianza promedio de texto del 96.83%, una confianza promedio de intención del 90% y una confianza global del 93.42%, métricas que validan la efectividad del proceso de preparación de datos implementado.

Recomendaciones

Establecer un pipeline de preprocesamiento versionado y reproducible.

Dado que el proceso de preparación de datos demostró tener un impacto directo sobre el rendimiento del sistema, se recomienda formalizar el pipeline de preprocesamiento como un componente versionado e independiente dentro de la arquitectura, documentando cada transformación aplicada normalización, filtrado de outliers, balanceo y augmentation con sus respectivos parámetros y resultados. Esta práctica garantiza la reproducibilidad de los experimentos y facilita la incorporación de nuevos datos sin comprometer la consistencia del corpus ya procesado (Schelter et al., 2022).

Ampliar el corpus con datos reales progresivamente.

El corpus actual está compuesto íntegramente por datos sintéticos, lo cual, si bien permite un control preciso sobre las características del dataset, limita la capacidad del modelo para generalizar ante variaciones lingüísticas imprevistas del lenguaje natural real. Se recomienda establecer un proceso continuo de incorporación de datos reales capturados durante la operación del sistema, integrándolos al corpus de entrenamiento mediante el mismo pipeline de normalización y augmentation implementado, a fin de reducir progresivamente la brecha entre el entorno sintético de entrenamiento y el entorno real de producción (Manning et al., 2008).

Implementar validación cruzada estratificada para evaluar el balanceo

Si bien el oversampling dirigido logró equilibrar las clases del corpus, se recomienda complementar esta estrategia con validación cruzada estratificada durante el entrenamiento del modelo NLU, asegurando que cada fold de validación mantenga la proporción de clases del corpus balanceado. Este enfoque permite evaluar de forma más rigurosa si el balanceo alcanzado es suficiente para garantizar una generalización uniforme entre clases, o si se requieren técnicas adicionales como SMOTE o augmentation diferenciado por clase (Kaur et al., 2023).

Definir umbrales mínimos de confianza por módulo para producción.

Los resultados del feature engineering evidenciaron una confianza promedio global del 93.42%, con una diferencia de 6.83 puntos porcentuales entre la confianza de texto (96.83%) y la

confianza de intención (90%). Se recomienda establecer umbrales mínimos de confianza por módulo que operen como filtros de seguridad dentro del pipeline; cuando una predicción no alcance el umbral definido, el sistema deberá activar un mecanismo de fallback como solicitar confirmación al usuario o escalar a un agente humano en lugar de propagar una clasificación de baja confianza hacia los módulos subsiguientes, lo cual podría comprometer la respuesta final del sistema.

Mantener y versionar los corpus RAG con ciclos periódicos de depuración

Dado que el módulo RAG opera sobre manuales técnicos y documentación de usuario sujetos a actualizaciones frecuentes, se recomienda establecer ciclos periódicos de revisión y depuración de los corpus documentales, aplicando el mismo pipeline de limpieza implementado en esta fase. Cambios en la documentación fuente como actualizaciones de la API REST o modificaciones en los manuales de usuario pueden introducir contenido desactualizado, duplicado o contradictorio que deteriore la precisión de la recuperación semántica. La implementación de un control de versiones sobre los corpus RAG garantiza que el sistema opere siempre sobre una base de conocimiento coherente y actualizada (Gao et al., 2024).

Evaluar el impacto del ruido sintético sobre el módulo ASR en condiciones reales

La inyección de ruido sintético durante la augmentation del corpus permitió simular errores fonéticos y tipográficos en un entorno controlado. Sin embargo, se recomienda realizar una evaluación comparativa entre el rendimiento del modelo entrenado con ruido sintético y su desempeño frente a grabaciones reales con condiciones acústicas adversas ruido ambiental, acentos regionales, velocidad de habla variable a fin de determinar si la diversidad de perturbaciones introducidas durante el entrenamiento es representativa de los escenarios reales de uso.

Referencias bibliográficas

Castellanos, A., Gómez, J., & Martínez, R. (2022). Intent detection in short and long utterances: Challenges and approaches in task-oriented dialogue systems. *Natural Language Engineering, 28*(4), 512–534. https://doi.org/10.1017/S1351324922000134

Feng, S., Nair, V., & Hovy, E. (2021). Survey on challenges of question answering in the medical domain. *arXiv*. https://arxiv.org/abs/2101.08272

Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., Dai, Y., Bi, J., Du, M., Li, H., Li, J., Wang, H., & Wang, W. (2024). Retrieval-augmented generation for large language models: A survey. *Computational Linguistics, 51*(2), 1123–1189. https://doi.org/10.1162/coli_a_00512

Hu, X., Jiang, Y., Liu, A., Huang, Z., Xie, P., Huang, F., Wen, L., & Yu, P. S. (2023). Entity-to-text based data augmentation for various named entity recognition tasks. En *Findings of the Association for Computational Linguistics: ACL 2023* (pp. 9072–9087). Association for Computational Linguistics. https://doi.org/10.18653/v1/2023.findings-acl.578

Kaur, H., Pannu, H. S., & Malhi, A. K. (2023). A systematic review on imbalanced data challenges in machine learning: Applications and solutions. *ACM Computing Surveys, 52*(4), 1–36. https://doi.org/10.1145/3343440

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. En *Advances in Neural Information Processing Systems* (Vol. 33, pp. 9459–9474). https://doi.org/10.48550/arXiv.2005.11401

Louvan, S., & Magnini, B. (2020). Recent neural methods on slot filling and intent detection for task-oriented dialogue systems: A survey. En *Proceedings of the 28th International Conference on Computational Linguistics* (pp. 480–496). International Committee on Computational Linguistics. https://doi.org/10.18653/v1/2020.coling-main.42

Manning, C. D., Raghavan, P., & Schütze, H. (2008). *Introduction to information retrieval*. Cambridge University Press. https://doi.org/10.1017/CBO9780511809071

Mikolov, T., Chen, K., Corrado, G., & Dean, J. (2013). Efficient estimation of word representations in vector space. *arXiv*. https://arxiv.org/abs/1301.3781

Ribeiro, M. T., Wu, T., Guestrin, C., & Singh, S. (2020). Beyond accuracy: Behavioral testing of NLP models with CheckList. *arXiv*. https://arxiv.org/abs/2005.04118

Schelter, S., Böse, J. H., Kirsten, J., Klein, T., & Seufert, T. (2022). Data cleaning and AutoML: Would an optimizer choose to clean? *Datenbank-Spektrum, 22*, 1–14. https://doi.org/10.1007/s13222-022-00413-2

To'xtasinov, A. I., & Sodiqov, V. S. (2025). The importance of data cleaning in data analysis. *Journal of New Century Innovations, 78*(2), 115–117. https://scientific-jl.com/new/article/view/19541

Wei, J., & Zou, K. (2019). EDA: Easy data augmentation techniques for boosting performance on text classification tasks. En *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing* (pp. 6382–6388). Association for Computational Linguistics. https://doi.org/10.18653/v1/D19-1670

Weld, H., Huang, X., Long, S., Poon, J., & Han, S. C. (2022). A survey of joint intent detection and slot filling models in natural language understanding. *ACM Computing Surveys, 55*(8), 1–38. https://doi.org/10.1145/3547138