Universidad Espíritu Santo

10 DE ABRIL DEL 2026

# Preparación y Procesamiento de Datos.

**INTEGRANTES:**

BRYAN ISMAEL ALVARADO QUIMIZ

DIEGO ANDRÉ ARÁMBULO VÍTORES

UNIVERSIDAD DE ESPECIALIDADES ESPÍRITU SANTO

## Preparación y Procesamiento de Datos

En esta fase el objetivo es convertir el texto bruto en un formato estructurado. Dado que no contamos con un dataset externo, el proceso comienza con la generación de un corpus controlado derivado de los diccionarios de intención y entendimiento presentes en el desarrollo del proyecto.

Dada la complejidad estructural del idioma español, el éxito de los modelos de inteligencia artificial depende en gran medida de la uniformidad de los datos de entrada. En este sentido, la normalización lingüística en tareas de Procesamiento de Lenguaje Natural para el idioma español es fundamental debido a la riqueza morfológica y el uso de tildes, lo cual puede generar una dispersión de datos si no se trata adecuadamente en la fase de preparación (Manning et al., 2008). Este proceso donde se realiza estandarización permite reducir la ambigüedad y asegura que las variaciones ortográficas del idioma no afecten la capacidad predictiva del sistema.

Debido a la naturaleza del pipeline de IA, consta de 3 módulos que tienen cada uno su propio dataset, para efecto de practicidad el proceso de procesamiento y limpieza de datos se a separado de la siguiente forma:

- Identificación de intenciones que puede tener el usuario
- Armar un dataset de frases, emulando solicitudes del usuario al sistemas, aproximadamente de 10 a 20 por cada intención detectada.
- Grabación de todas las frases encontradas en dicho dataset para realizar las pruebas del modelo/API ASR
- Para el módulo RAG, se necesitaran 2 manuales, el de usuario que sí existe, y uno generado sintéticamente a partir del contrato de la api rest de búsqueda de archivos, ambos archivos generados en formato Markdown para mayor entendimiento y procesamiento, agregándoles ruido y contenido no deseable fuera de contexto.

Los dataset mencionado con anterioridad, deberán pasar por procesos de filtrado semántico, léxico y de normalización del lenguaje, para ella se elaboró el siguiente plan:

- ASR (Reconocimiento de voz)
    - Obtener muestras de grabaciones reales con distintas voces y tonos
    - Normalización de texto identificado*
- NLP (Identificación de patrones/intenciones)
    - Utilización de vectores de texto para detectar entidades en el contenido textual proveniente del módulo 1, tales como intenciones y usuarios
    - Normalización de texto identificado*
- RAG (sistemas expertos basados en manuales como base conocimiento)
    - Eliminación de contenido repetido o redundante
    - Limpieza de Manuales - Eliminar
        - Data irrelevante (imagenes y tablas)
        - Data duplicada (definiciones y enunciados)
        - Errores de Typo, cadenas de texto sin sentido
        - Data no relacionada al texto (fuera de contexto)
    - Normalización de texto identificado*

(*)La normalización de texto incluye manejo constante de minúsculas, reemplazo de acentos, caracteres extraños, eliminación de redundancia, ajuste semántico y mejoras al manejo de fecha ej: primero de marzo del dos mil veinte y cuatro, se traduce a 2024-03-01

**Pipeline de limpieza de datos.**

El módulo 3 (El sistema experto basado en estrategias RAG), debido a su naturaleza, es el más propenso a tener necesidades de ser depurado, esto porque los documentos como manuales de usuario, manuales técnicos, flujos operacionales, diagramas de uso, instructivos en general, son fuentes editadas y mantenidas por personal propenso al fallo, como lo son las faltas ortográficas, fallas semánticas, y contaminación de contenido, es por eso que el módulo indicado recibió una depuración específica en diferentes aspectos en sus corpus, como son:

- Purga de imágenes y tablas, elementos duplicados.
- Datos relevantes al texto y contexto.
- Errores ortográficos y Typos.

El éxito de la arquitectura RAG reside en la calidad en la que se recupera la información, la simplicidad del formato de entrada es determinante al momento de su uso. Los sistemas de generación aumentada por recuperación operan con mejor eficacia sobre archivos de texto plano debido a la ausencia de metadatos complejos y estructuras de formato que suelen introducir ruido semántico durante el proceso de vectorización. Al quitar datos complejos, el modelo de lenguaje se enfoca exclusivamente en el contenido léxico, facilitando una recuperación más precisa de los fragmentos relevantes.

Para la implementación del sistema se optó por el uso de archivos de texto plano, priorizando la simplicidad estructural del conocimiento base. Esta decisión se fundamenta en que la precisión de los sistemas de Generación Aumentada por Recuperación (RAG) depende fundamentalmente de la etapa previa de tratamiento de datos; al transformar archivos con estructuras complicadas en formatos de texto sencillo, se logra disminuir de forma notable las imprecisiones durante la creación de los vectores semánticos (Lewis et al., 2020). Por tanto, la normalización realizada en los documentos de Entendimiento e Intención no es solo estética, sino una optimización del espacio vectorial para que el modelo sea óptimo.

Desde nuestra perspectiva técnica en el desarrollo de sistemas de recuperación de información, consideramos a Markdown como el formato superior para el procesamiento de datos en arquitecturas RAG, debido a su capacidad para estructurar contenido de manera ágil sin perder la jerarquía lógica del documento. A diferencia de los archivos de texto plano convencionales, Markdown permite que el modelo identifique claramente encabezados, tablas y listas, lo cual facilita una segmentación semántica mucho más coherente. Esta estructura simplificada es vital porque la integridad de las representaciones vectoriales en sistemas de recuperación semántica depende de la preservación de la estructura lógica del texto; en este sentido, los formatos ligeros de marcado facilitan una segmentación coherente que minimiza el ruido estructural durante la generación de embeddings (Lewis et al., 2020). Al hacer uso este formato, se garantiza que el contexto recuperado por el modelo sea preciso y mantenga una conexión jerárquica original de la información.

Dentro de las arquitecturas de generación aumentada por recuperación (RAG), la integración de reglas heurísticas opera como un mecanismo de depuración estratégica que elimina contenido irrelevante antes de su procesamiento por el modelo de lenguaje, optimizando así el aprovechamiento de la ventana de contexto. A diferencia de los enfoques basados exclusivamente en similitud vectorial, esta capa lógica adicional permite descartar ruido documental como cláusulas legales, fragmentos truncados o duplicados conservando únicamente los pasajes con valor operativo real. Como señalan Gao et al. (2024), la calidad de la recuperación en sistemas RAG depende críticamente de la fase de preprocesamiento, donde la aplicación de criterios de segmentación y filtrado basado en reglas reduce la contaminación semántica y mejora la precisión de las representaciones vectoriales. Al aplicar criterios heurísticos de purga, se logra una ventana de contexto más limpia, lo que reduce el costo computacional y minimiza la probabilidad de alucinaciones en el modelo generativo.

Ejecutando el pipeline de limpieza sobre los corpus de manual, en este caso técnicos y de usuario, obtuvimos mejoras en la reducción de ruido y extensión lógica de los mismos, según podremos apreciar en la siguiente comparativa.

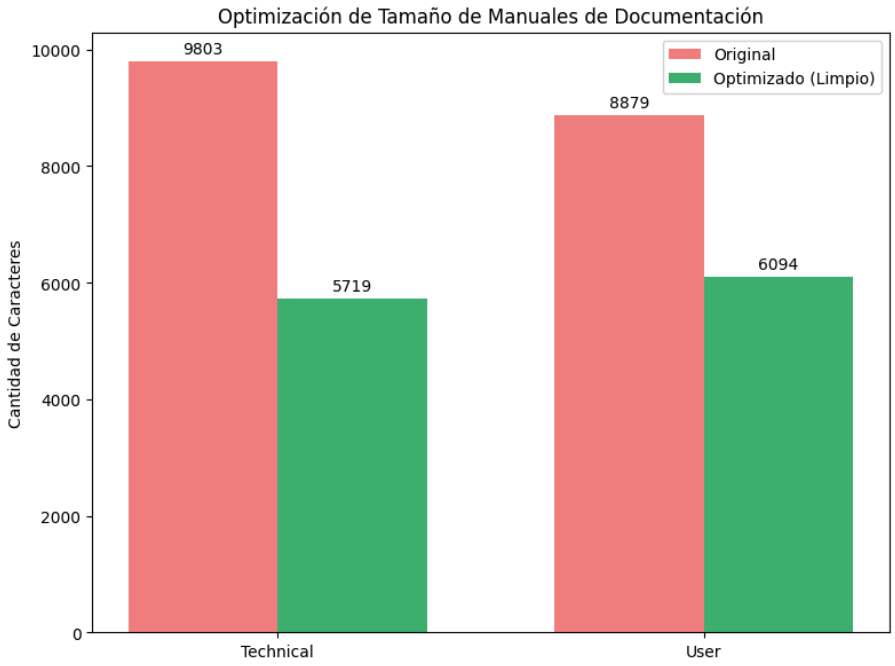


**Fig 1**: Autoría propia co creada con IA

**Feature engineering avanzado.**

En tareas de Procesamiento de Lenguaje Natural (PLN), no es suficiente con detectar términos aislados; es necesario construir descriptores que capturen el contexto y la relación entre entidades. Es primordial ya que la normalización lingüística en tareas de PLN para el idioma español es fundamental debido a la riqueza morfológica y el uso de tildes, lo cual puede generar una dispersión de información en la data si no se trata correctamente en la fase de entrenamiento (Manning et al., 2008). Por consiguiente, una ingeniería de atributos robusta actúa como el puente que transforma el lenguaje natural en un conjunto de características numéricas donde las intenciones similares se agrupan y las divergentes se dispersan, minimizando el error en la fase de entrenamiento colaborando con la mejora del mismo.

Dentro del feature engineering, tenemos el caso particular de no poseer variables numéricas normales, sino que trabajamos más con datos cualitativos y entidades detectadas, para lograr nuestro objetivo de evaluar la efectividad de nuestro dataset y análisis de datos, haremos una comparación directa entre la intención marcada en el dataset de forma sintética (debido a que la data de entrada no existe y debe ser generada a partir de registros similares a los encontrados en el mundo real), y la intención que el pipeline resuelve contra el texto detectado del audio cargado al mismo, esto al final nos dara una calificacion binaria y a su vez nos generará un promedio de confianza, como lo detallamos a continuación, donde figura la confianza detectada al comparar textos y la confianza al comparar la intención marcada y los siguientes indicadores.

- **Confianza promedio de texto**: 96.83%
- **Confianza promedio de intención**: 90%
- **Confianza promedio global**: 93.42%

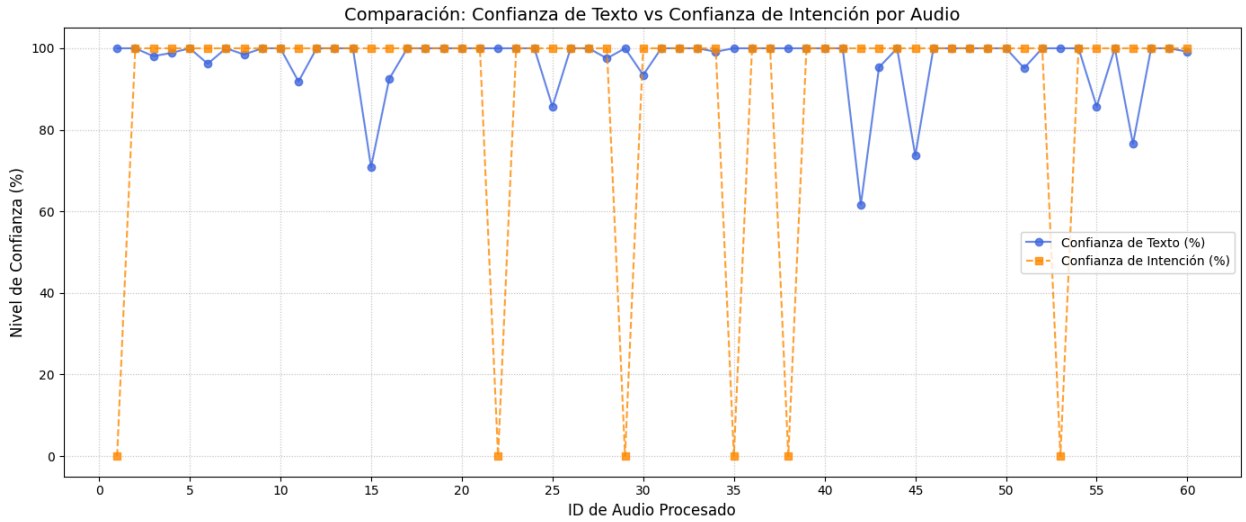


**Fig 2**: Autoría propia co creada con IA

**Estrategias de balanceamiento de datos.**

Inicialmente el dataset creado manualmente, tenía un desbalance con tendencia y sesgo a registros de tipo LD (Intención de Listar Documentos), esto podría generar que los modelos en caso de ser entrenados, tengan una inclinación sobre el dato mayor entrenado, es por eso que se requiere normalizar y emparejar los registros, como se necesitan solamente igualar la misma población de registros, se usará una técnica simple de Oversampling dirigido, que tendrá como resultado generar más resultado para los otros tipo de intención, DD (Descarga de documento) y N (Navegación), con un total de 21 registros nuevos generados para balancear el dataset, no da un total de 81 items en el corpus del dataset, como se puede apreciar en el diagrama siguiente.

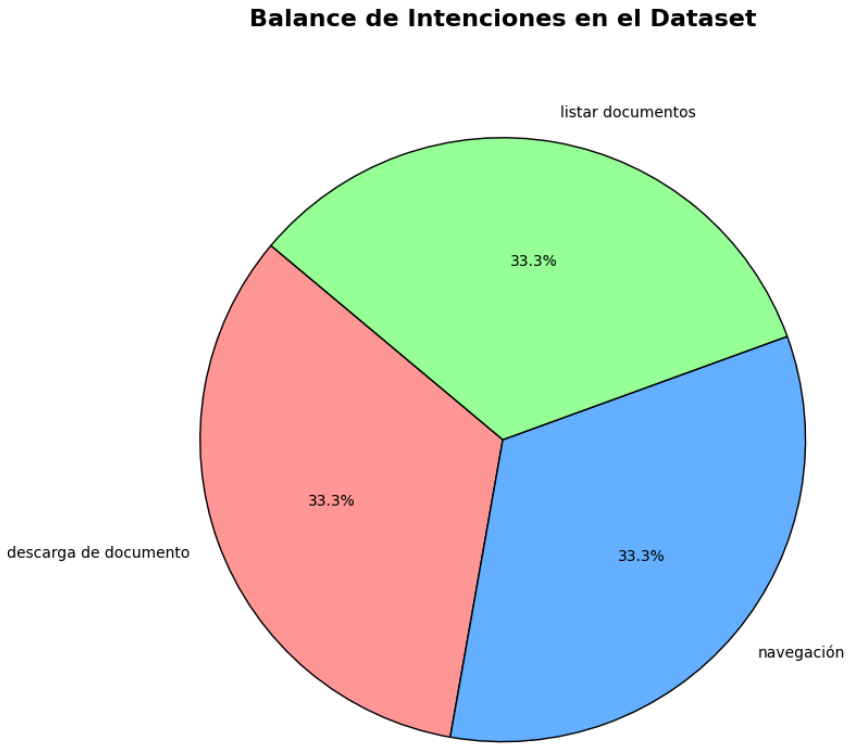


**Fig 3**: Autoría propia co creada con IA

Cuando un dataset presenta una inclinación desproporcionada, los modelos tienden a optimizar la precisión global a expensas de las clases minoritarias, lo que compromete la capacidad de generalización del sistema. Para contrarrestar este fenómeno, la implementación de técnicas de Oversampling dirigido permite nivelar la representación de las distintas categorías en este caso, las intenciones de descarga y navegación garantizando que el pipeline de aprendizaje cuente con una base comparativa balanceada. Este método es esencial, ya que el equilibrio del dataset mediante técnicas de sobremuestreo no solo mitiga el sesgo hacia las etiquetas dominantes, sino que mejora significativamente la robustez del modelo al proporcionar una exposición uniforme a las características distintivas de cada clase (Kaur et al., 2023). Mitigando la optimización de precisión que el modelo pueda generar.

**Técnicas de data augmentation (según el tipo de datos).**

Bajo la particularidad del dataset compartido por el módulo 1 y 2, al encontrarse en un desbalance inicial con 30 registros y ser de múltiples dimensiones (texto natural, intención, estado y contexto documental), se decidió usar una combinación entre sustitución de entidades (NER-based) para generar más entidades como nombres, fechas y ciudades, así como también el agregado de Ruido sintético (Noise Injection), ya que en la muestra tenemos escenarios donde los textos contienen uso de caracteres errados, y mala formación de letras (uso de números como vocales, repetición de cadenas de letras, uso de caracteres especiales, etc), siendo ambas técnicas fundamentales, al provenir en ambientes reales de ASR y texto ingresado por usuarios, es decir, es propenso a fallos y errores en su digitación.

En este caso para poder normalizar el dataset principal, fue necesaria la tecnica de insercion de prefijos al principio y fin, básicamente es tomar las existentes minorías y crear variaciones de estas con la implementación de sinónimos en la mayoría de ocasiones, siendo la mejor opción para nuestro dataset porque conserva la semántica, tiene eficiencia computacional y reusa lo que ya sabemos funciona bien (casos reales ya registrados).

En su estudio sobre técnicas de aumento de datos para clasificación de texto, Jason Wei y Kai Zou (2019) evidencian que métodos heurísticos simples, basados en reglas, pueden mejorar significativamente el rendimiento de modelos en conjuntos de datos reducidos, alcanzando resultados similares a enfoques más complejos pero con un menor costo computacional, luego del aumento podemos observar la diferencia entre la longitud de textos originales y aumentados.

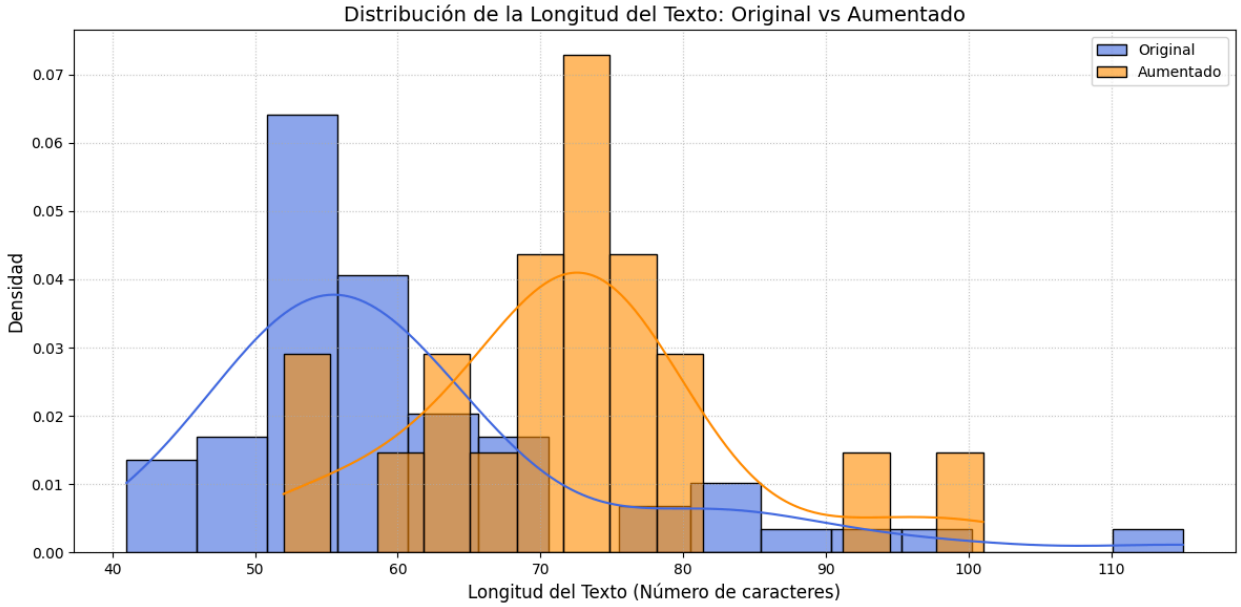


**Fig 4**: Autoría propia co creada con IA

En el entrenamiento de modelos de lenguaje para entornos con datos limitados, NER-based Data Augmentation se presenta como una solución técnica para mitigar el sobreajuste en entornos con escasez de datos. Mediante la sustitución dinámica de entidades por alternativas de la misma categoría semántica o sintáctica, el sistema de detección de intenciones aprende patrones estructurales en lugar de memorizar instancias léxicas específicas. Esta aproximación es fundamental para garantizar la robustez del modelo, ya que la generación controlada de variantes sintéticas permite mantener un rendimiento estable incluso ante entradas con ruido ortográfico, variaciones morfológicas o errores tipográficos (Hu et al., 2023). Como resultado, se fortalece la capacidad de generalización del clasificador, priorizando la identificación de la intención subyacente sobre la dependencia de la superficie textual original.

La capacidad de un pipeline de comprensión de lenguaje natural (NLU) frente a entradas provenientes de sistemas ASR o lenguaje coloquial varía según su capacidad para procesar texto defectuoso. La inyección de ruido sintético permite que el modelo practique en escenarios de falla controlada, simulando errores fonéticos y tipográficos para fortalecer la resiliencia de la detección de intenciones. Este enfoque se fundamenta en que la robustez de un sistema de comprensión de lenguaje natural ante el ruido sintáctico es directamente proporcional a la diversidad de las perturbaciones introducidas durante la fase de preparación de datos (Wei & Zou, 2019). Por ende, para que el pipeline tenga una mayor identificación directa de lenguaje con diferentes términos coloquiales este debe ser expuesto a fallos controlados durante su entrenamiento.

**Referencias bibliográficas**


- Manning, C. D., Raghavan, P., & Schütze, H. (2008). *Introduction to Information Retrieval*. Cambridge University Press. https://doi.org/10.1017/CBO9780511809071
- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. Advances in Neural Information Processing Systems*, 33, 9459–9474. https://doi.org/10.48550/arXiv.2005.11401
- Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., Dai, Y., Bi, J., Du, M., Li, H., Li, J., Wang, H., & Wang, W. (2025). *Retrieval-augmented generation for large language models: A survey. Computational Linguistics*, 51(2), 1123–1189. https://doi.org/10.1162/coli_a_00512
- Wei, J., & Zou, K. (2019). *EDA: Easy data augmentation techniques for boosting performance on text classification tasks*. Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP). https://doi.org/10.18653/v1/D19-1670
- Hu, X., Jiang, Y., Liu, A., Huang, Z., Xie, P., Huang, F., Wen, L., & Yu, P. S. (2023). *Entity-to-text based data augmentation for various named entity recognition tasks.* Findings of the Association for Computational Linguistics: ACL 2023, 9072–9087. https://doi.org/10.18653/v1/2023.findings-acl.578
- Kaur, H., Pannu, H. S., y Malhi, A. K. (2023). A Systematic Review on Imbalanced Data Challenges in Machine Learning: Applications and Solutions. *ACM Computing Surveys*, 52(4), 1-36. https://doi.org/10.1145/3343440
- Wei, J., & Zou, K. (2019). EDA: *Easy Data Augmentation Techniques for Boosting Performance on Text Classification Tasks*. arXiv preprint arXiv:1901.11196. https://doi.org/10.48550/arXiv.1901.11196