24 DE ABRIL DEL 2026

SIMULACIÓN DE ESCENARIOS CRÍTICOS

INTEGRANTES:

BRYAN ISMAEL ALVARADO QUIMIZ

DIEGO ANDRÉ ARÁMBULO VÍTORES

UNIVERSIDAD DE ESPECIALIDADES ESPÍRITU SANTO

Simulación de datos ruidosos e incompletos

Una de los principales aspectos de un sistema a ser implementado, es su tolerancia y comportamiento a información basura o en mal estado que pueda llegar a procesar por ingreso de datos del mundo real, está margen aumenta según las brechas de interacción con un usuario incrementan, debido al factor de error humano el cual ningún sector es inmue.

Incluso expertos altamente calificados producen anotaciones inconsistentes al etiquetar los mismos datos clínicos, generando una verdad de referencia parcial que degrada directamente la precisión, complejidad y confiabilidad del modelo de IA entrenado (Roshan et al., 2023).

Debido a esto, se realizarán pruebas sobre los modelos propuestos para poder obtener métricas en cuanto a su comportamiento frente a data que los enfrentará a situaciones borde y que saldrán del umbral de normalidad al cual están normalizados. Podremos resumir las siguientes pruebas para los diferentes módulos involucrados.

- **Módulo 1.- ASR (AUDIOS)**
    - Ruido de fondo
    - Variedad de acentos fonéticos
    - Audios cortados o incompletos
    - Otro idioma
- **Módulo 2.- PLN / ALU (INTENCIONES)**
    - Detección de intención bajo texto con ruido y comparación contra dato etiquetado
- **Módulo 3.- RAG (BASE DE CONOCIMIENTO)**
    - Uso de manuales con ruido o data no relevante
    - Comparación de respuesta del RAG aplicando LLM local y verificar si los tokens esperados fueron identificados

Pruebas y resultados módulo ASR

En este caso, tenemos una muestra de data sintética de 21 audios, representando diferentes cambios en la huella sonora que el api de reconocimiento está normalmente siendo enfrentada, los escenarios con ruido de fondo se vuelven muy interesantes de analizar en esta sección, ya que, La causa principal de degradación del rendimiento en sistemas ASR es la presencia de ruido ambiental durante la fase de prueba, generando un desajuste entre los entornos de entrenamiento y evaluación que ninguna arquitectura logra ignorar (Dua et al., 2023).

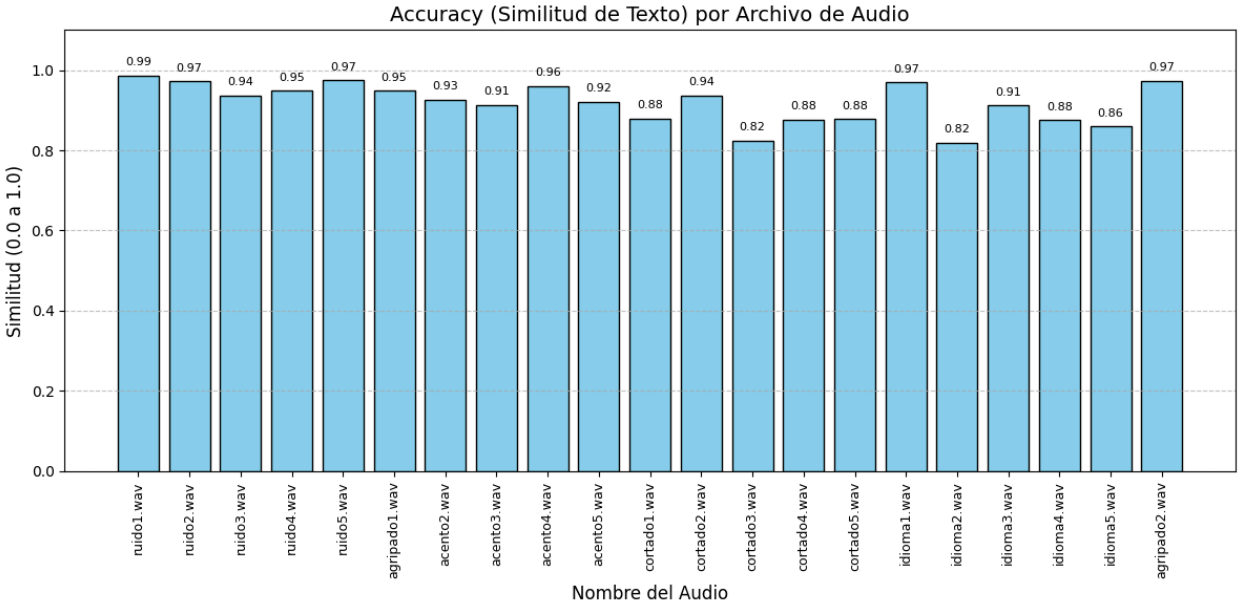

Figura 1: *Similitud expresada como accuracy en diagrama de barras*

Nota. Autoría propia

La comparación directa de la transcripción del audio fue realizada con su contraparte textual etiquetada con anterioridad como *Ground truth*, ya que representaba lo que exactamente se estaba pronunciando en los audios, podemos evidenciar que el valor promedio de accuracy es de *91.85%,* lo cual califica a la funcionalidad del ASR como muy estable y robusta frente a los casos adversos presentados anteriormente.

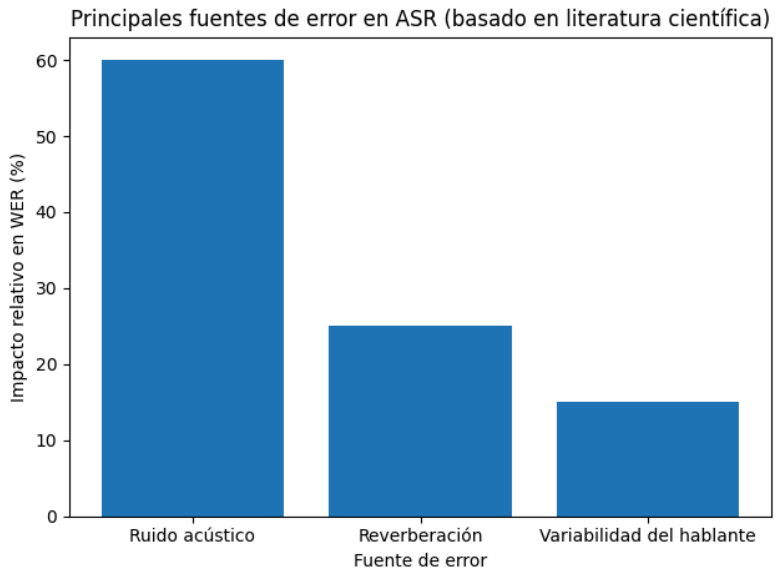

Figura 2: *Comparativa de agente influyentes de error en ASR en escala WER*

Nota. Por Shi et al., (2023). A comprehensive study on the effectiveness of ASR representations for noise-robust speech emotion recognition

La literatura científica demuestra que el ruido acústico es el factor más determinante en la degradación del rendimiento de sistemas ASR, ya que impacta directamente la señal de entrada, incrementando significativamente el Word Error Rate (WER), seguido por efectos acústicos como la reverberación y factores lingüísticos como la variabilidad del hablante. De igual forma debemos ser críticos en que estos resultados fueron obtenidos usando Google Web Speech API, la cual está basada en un modelo universal pre entrenado en más de 300 idiomas y 12 millones de horas de audio, logrando cobertura multilingüe sin precedentes (Zhang et al., 2023).

Del mismo modo, dentro del banco de pruebas, podemos obtener la inclusión de escenarios con *Drift*, la forma de aplicarlo fue al cambiar los entornos de audio, como:

- Acentos del hablante: distintos puntos geográficos
- Dispositivo de grabación: micrófono laptop, micrófono teléfono móvil
- Formatos distintos de audios: OGG, WAV

Pruebas y resultados módulo PLN de intenciones

Continuando con las pruebas integrales, para el módulo de intenciones tomaremos como base el mismo dataset sintético antes usado con el ASR, pero esta vez comparando la identificación de intenciones usando el texto transcrito del audio como el contenido original, y otro texto intencionalmente adulterado para generar ruido y alterar los resultados del módulo 2.

La inyección de ruido textual en datos de entrada degrada la detección de intenciones en modelos BERT hasta un 13.5% en accuracy, consolidando el ruido como el escenario de prueba de estrés más revelador de la robustez real del sistema (Simha et al., 2021)

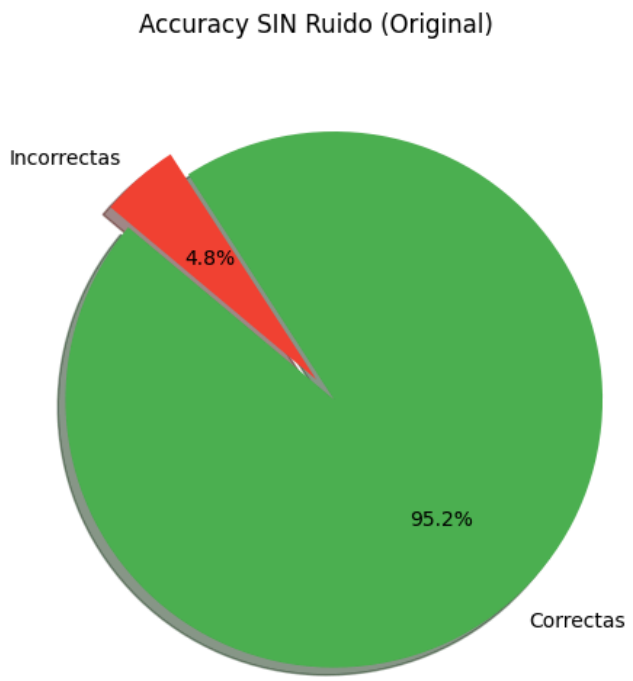

Figura 3: *Accuracy de intenciones con texto original*

Nota. Autoría propia

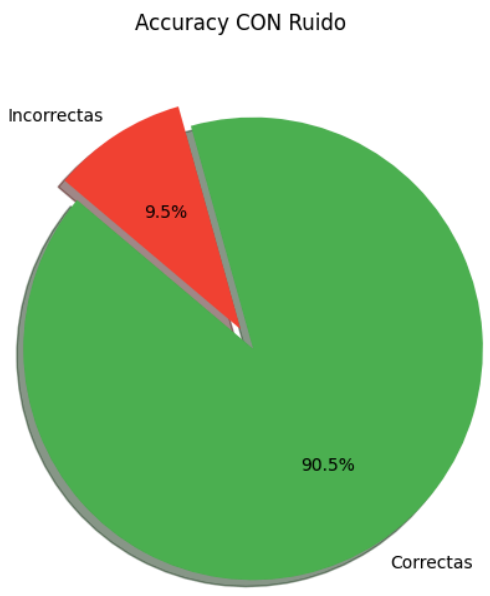

Figura 4: *Accuracy de intenciones con texto adulterado con ruido sintético*

Nota. Autoría propia

Con base en los resultados obtenidos, se observa una degradación en el rendimiento del modelo en la identificación de intenciones, evidenciada en una disminución de 4.76 puntos porcentuales en la tasa de aciertos. Este comportamiento puede explicarse por la naturaleza del modelo basado en arquitecturas tipo BERT, cuyo fine-tuning con datasets adversariales como ANLI tiende a incrementar la confianza en las predicciones sin una mejora proporcional en la precisión, especialmente en escenarios fuera de distribución. Este fenómeno, conocido como *overconfidence*, ha sido documentado en la literatura. En este sentido, He et al. (2023) señalan que "los modelos finamente ajustados aún sufren de predicciones excesivamente confiadas, particularmente en entornos fuera del dominio".

Podemos mencionar entonces que los modelos fine-tuned con ANLI tienden a ser más seguros en sus predicciones, pero no necesariamente más correctos, lo que introduce problemas de calibración y riesgo en entornos reales con datos ruidosos o fuera de distribución, a continuación podremos revisar las métricas reportadas por el modelo base directo de su sitio oficial.

BENCHMARK XNLI — EVALUACIÓN MULTILINGÜE

Idioma	Dataset	Accuracy (%)	Rendimiento visual
Español es	XNLI	93.7	93.7%

BENCHMARK ANLI — EVALUACIÓN ADVERSARIAL POR RONDA

Ronda	Descripción	Accuracy (%)	Rendimiento visual
ANLI-R1 ronda 1	Adversarial — dificultad baja	68.5	68.5%
ANLI-R2 ronda 2	Adversarial — dificultad media	53.6	53.6%
ANLI-R3 ronda 3	Adversarial — dificultad alta	49.0	49.0%

RESUMEN COMPARATIVO

Benchmark	Tipo	Score	Interpretación
XNLI-es	multilingüe	93.7%	Muy alto — clase de referencia
ANLI-R1	adversarial	68.5%	Aceptable — nivel base adversarial
ANLI-R2	adversarial	53.6%	Moderado — mayor complejidad
ANLI-R3	adversarial	49.0%	Desafiante — máxima adversarialidad

Figura 5: *Tabla comparativa de rendimiento del modelo con diferentes datasets*

Nota. Por Vicgalle. (2023). *xlm-roberta-large-xnli-anli* [Model card]. Hugging Face

Basado en la literatura se evidencia que La inyección de ruido textual (typos, caracteres malformados, deformaciones) es el método de prueba de estrés más directo y representativo del mundo real para evaluar la robustez de modelos NLP, incluyendo detección de intenciones, superando en representatividad al ataque adversarial puro (Wang et al., 2021).

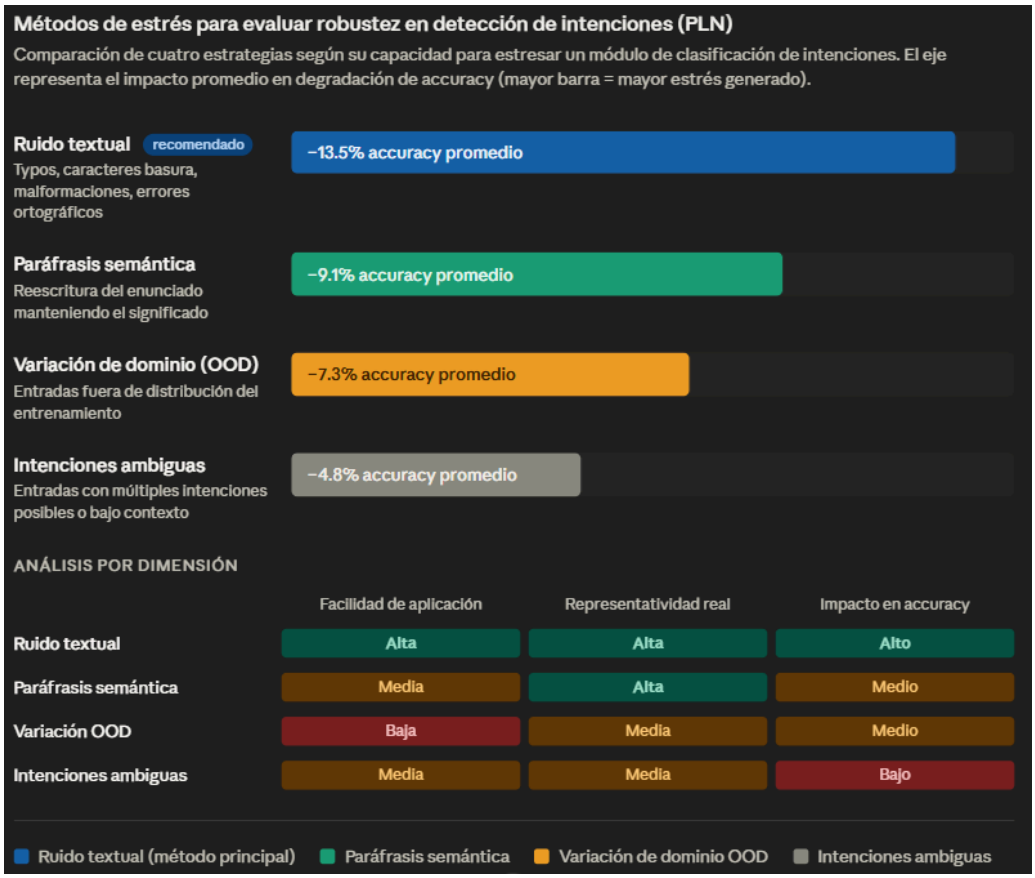

Figura 6: *Tabla comparativa de métodos de evaluar robustez de módulos PLN*

Nota. Por Sengupta et al. (2021); Castillo-Bolado et al. (2025); Rust et al. (2025)

Pruebas y resultados módulo RAG de base documental

Como último módulo sometido a pruebas de estrés, se aborda el componente encargado de gestionar la base de conocimientos institucional, construida a partir de manuales operativos y flujos de trabajo propios del sistema. Para esta evaluación, se introduce ruido deliberado en las fuentes documentales de entrada, con el propósito de analizar comparativamente su impacto en la capacidad de resolución de consultas. Los resultados obtenidos constituyen evidencia empírica del efecto que tiene la incorporación de documentación no depurada como origen de datos en sistemas que implementan técnicas de Generación Aumentada por Recuperación (RAG, por sus siglas en inglés).

Este enfoque de prueba es coherente con lo documentado en la literatura especializada: la presencia de ruido o información contradictoria durante la fase de recuperación puede afectar negativamente la calidad de las salidas generadas por sistemas RAG, situación que se describe figurativamente como "la desinformación puede ser más perjudicial que la ausencia total de información"; mejorar la resistencia del sistema RAG ante entradas adversariales o contrafácticas se ha convertido en un indicador de rendimiento clave y en un foco creciente de investigación (Gao et al., 2023).

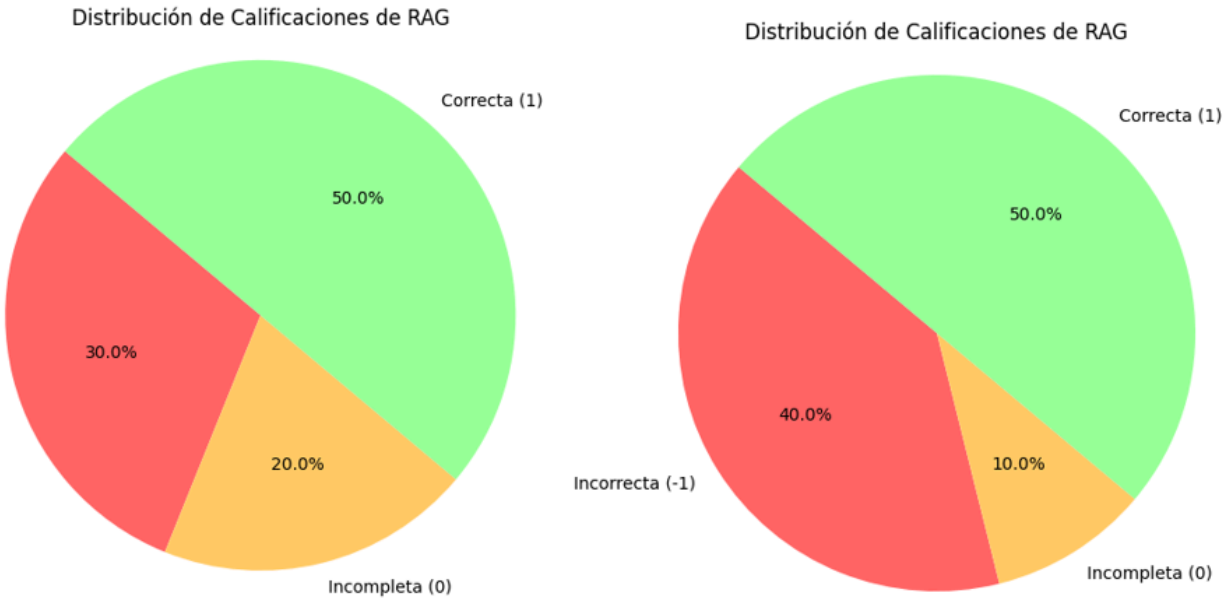

Figura 7: *Distribución de módulo RAG con data limpia y contaminada*

Nota. Autoría propia

El anterior gráfico representa la distribución de los 3 escenarios básicos que podremos enfrentar en una implementación de sistema experto basado en técnicas RAG, que son una respuesta correcta, incorrecta o incompleta, esto basado en el principio de tokens o secciones de respuesta esperados, es decir que para considerarse correcta, la respuesta debe contener todo el contexto esperado. Con la evidencia anterior podemos sustentar que el ruido ingresado baja la calidad de respuesta, para este caso particular hubo un aumento de respuestas incorrectas en un 10% donde antes eran categorizadas como incompletas solamente.

La evaluación de sistemas basados en Retrieval-Augmented Generation (RAG) mediante la inyección controlada de ruido en los documentos de la base de conocimiento constituye una estrategia válida para analizar su robustez, dado que el desempeño de estos sistemas depende directamente de la calidad de la información recuperada. Diversos estudios han demostrado que la inclusión de información irrelevante o adversarial en los documentos de contexto degrada significativamente el rendimiento de los modelos y puede inducir respuestas incorrectas o inconsistentes (Jia & Liang, 2017; Lewis et al., 2020). Asimismo, la literatura ha evidenciado que la presencia de ruido en los datos de entrada puede afectar negativamente la capacidad de generalización de los modelos de aprendizaje profundo (Zhang et al., 2017), reforzando la necesidad de evaluar estos sistemas bajo condiciones adversas.

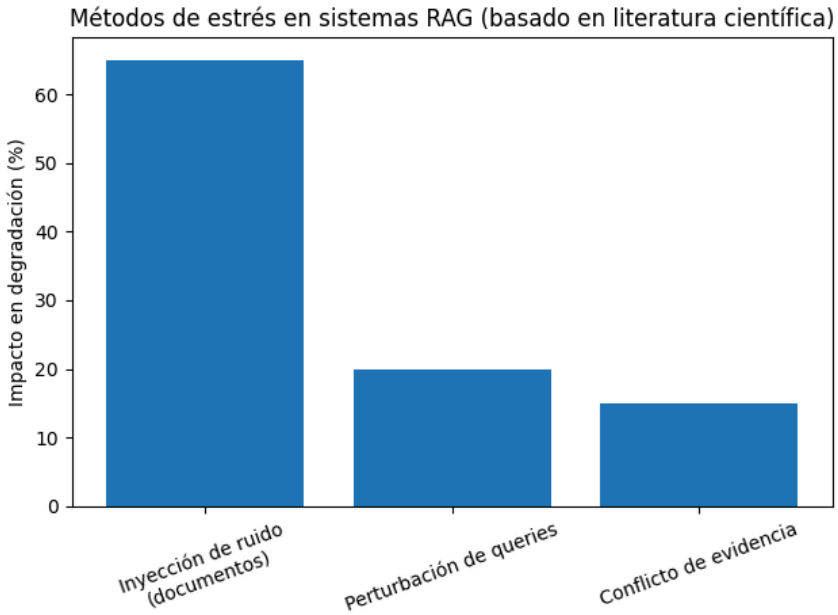

Figura 8: *Métodos predominantes de estrés en sistemas RAG*

Nota. Por Fang et al. (2024). Enhancing Noise Robustness of Retrieval-Augmented Language Models with Adaptive Adversarial Training

Conclusiones de resultados obtenidos

Los resultados de las pruebas de estrés mediante la inyección de ruido sintético en datasets, manuales (RAG) y señales de audio (ASR) evidencian una degradación significativa del rendimiento del sistema, reflejada en la disminución de métricas como confianza y precisión, así como en el incremento del Word Error Rate (WER) y errores semánticos.

En el módulo ASR, el ruido acústico e incompleto deteriora la calidad de la transcripción, propagando errores hacia el NLU / PLN. En este último, el ruido textual incrementa la ambigüedad y reduce la capacidad de generalización. En el caso de RAG, la presencia de información irrelevante o contradictoria afecta el proceso de recuperación, generando respuestas inconsistentes o alucinadas.

En conjunto, se observa un efecto acumulativo donde los errores en etapas iniciales se amplifican a lo largo del pipeline. Estos resultados confirman que el ruido es un factor crítico de degradación, y que su evaluación controlada es esencial para validar la robustez de sistemas de IA en entornos reales más aún con información que tuvo origen de factor humano.

Referencias bibliográficas

Roshan, T., et al. (2023). The impact of inconsistent human annotations on AI driven clinical decision making. npj Digital Medicine, 6, 26. https://doi.org/10.1038/s41746-023-00773-3

Dua, S., Aggarwal, R. K., & Biswas, M. (2023). Noise robust automatic speech recognition: Review and analysis. *International Journal of Speech Technology*, *26*, 905–930. https://doi.org/10.1007/s10772-023-10033-0

Shi, X., He, J., Li, X., & Toda, T. (2023). *A comprehensive study on the effectiveness of ASR representations for noise-robust speech emotion recognition* (arXiv:2311.07093v4). arXiv. https://doi.org/10.48550/arXiv.2311.07093

Zhang, Y., et al. (2023). Google USM: Scaling automatic speech recognition beyond 100 languages. *arXiv*:2303.01037. https://doi.org/10.48550/arXiv.2303.01037

Simha, A., Mallya, D., & Gupta, A. (2021). *On the robustness of intent classification and slot labeling in goal-oriented dialog systems to real-world noise* (arXiv:2104.07149). arXiv. https://doi.org/10.48550/arXiv.2104.07149

Vicgalle. (2023). *xlm-roberta-large-xnli-anli* [Model card]. Hugging Face

He, G., Chen, J., & Zhu, J. (2023).
Preserving pre-trained features helps calibrate fine-tuned language models.
International Conference on Learning Representations (ICLR). Recuperado de https://openreview.net/forum?id=NI7StoWHJPT

Zhang, C., Bengio, S., Hardt, M., Recht, B., & Vinyals, O. (2017).
Understanding deep learning requires rethinking generalization.

ICLR / Nature-related discussions. https://doi.org/10.48550/arXiv.1611.03530

Jia, R., & Liang, P. (2017). *Adversarial examples for evaluating reading comprehension systems*. **Transactions of the Association for Computational Linguistics**. https://doi.org/10.1162/tacl_a_00015

Fang, F., Bai, Y., Ni, S., Yang, M., Chen, X., & Xu, R. (2024). *Enhancing noise robustness of retrieval-augmented language models with adaptive adversarial training*. ACL.

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., … Riedel, S. (2020). *Retrieval-augmented generation for knowledge-intensive NLP tasks*. **Advances in Neural Information Processing Systems (NeurIPS)**. https://doi.org/10.48550/arXiv.2005.11401

Wang, X., et al. (2021). TextFlint: Unified multilingual robustness evaluation toolkit for natural language processing. En *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics* (pp. 347–355). Association for Computational Linguistics. https://doi.org/10.18653/v1/2021.acl-demo.41

Sengupta, S., Krone, J., & Mansour, S. (2021). On the robustness of intent classification and slot labeling in goal-oriented dialog systems to real-world noise. En *Proceedings of the 3rd Workshop on NLP for Conversational AI* (pp. 68–79). ACL. https://doi.org/10.18653/v1/2021.nlp4convai-1.7

Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., Dai, Y., Sun, J., & Wang, H. (2023). Retrieval-augmented generation for large language models: A survey. arXiv:2312.10997. https://doi.org/10.48550/arXiv.2312.10997

Castillo-Bolado, D., Davidson, T., & Rosa-Remedios, C. B. (2025). Large language models robustness against perturbation. *Scientific Reports*, *15*, 5392. https://doi.org/10.1038/s41598-025-29770-0

Rust, P., Fomicheva, M., & Blain, F. (2025). *Exploring robustness of multilingual LLMs on real-world noisy data* (arXiv:2501.08322). arXiv. https://doi.org/10.48550/arXiv.2501.08322